TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIẾN ĐỘ ĐỒ ÁN BIGDATA

Phát hiện các khía cạnh gây không hài lòng của khách hàng từ dữ liệu phản hồi trên các sàn thương mại điện tử tại Việt Nam

Giảng viên: TS. Huỳnh Thái Học

Thời điểm tổng hợp báo cáo: 28/10/2026

Bảng 1: Thành viên thực hiện

MSSV	Họ và tên	Lớp
2001230757	Huỳnh Quang Sang	14DHTH13
2001230915	Phan Đức Thể	14DHTH13
2001231033	Đỗ Trọng Vĩ	14DHTH06

1 MỤC TIÊU VÀ PHẠM VI

Nhóm đã triển khai pipeline CSV - HDFS - Spark - Kafka replay - Airflow và sản phẩm ReviewLens. Báo cáo tiến độ tổng hợp ngày 28/10/2026 từ minh chứng thực nghiệm lưu ngày 12/10 và đối soát bổ sung ngày 15/10; không coi ngày tổng hợp là một lần chạy mới toàn hệ thống.

Mục tiêu là nhận biết khía cạnh được nhắc trong review 1-2 sao theo nền tảng và thời gian, đồng thời giải thích được block HDFS, partition, shuffle, checkpoint và phụ thuộc DAG. Quy trình phải có số đếm đối soát và có thể chạy lại.

Đơn vị quan sát là review ứng dụng Google Play của Shopee, Lazada, Sendo và Tiki trong giai đoạn 2013 đến 08/2022. Kết quả chưa chứng minh quan hệ nhân quả hoặc đại diện cho toàn bộ khách hàng Việt Nam; nhận diện khía cạnh hiện ở mức baseline.

MỤC LỤC

1 MỤC TIÊU VÀ PHẠM VI 1
2 NGUỒN VÀ CẤU TRÚC DỮ LIỆU 3
3 KIẾN TRÚC HỆ THỐNG 4
4 NỘI DUNG ĐÃ TRIỂN KHAI 5
5 MINH CHỨNG HDFS VÀ XỬ LÝ BATCH 6
6 MINH CHỨNG KAFKA VÀ AIRFLOW 7
7 KẾT QUẢ PHÂN TÍCH HIỆN TẠI 8
8 SẢN PHẨM REVIEWLENS VÀ KIỂM TRA HIỆN TẠI 9
9 KHÓ KHĂN PHẦN CHƯA HOÀN THÀNH VÀ KẾ HOẠCH TIẾP 10
9.1 Phần chưa hoàn thành 10
9.2 Kế hoạch hoàn thiện 10
10 PHÂN CÔNG VÀ LỘ TRÌNH TRONG NĂM TUẦN 11
10.1 Tuần 1 Khảo sát bài toán và chuẩn bị môi trường 11
10.2 Tuần 2 Lưu trữ và làm sạch dữ liệu bằng Spark 11
10.3 Tuần 3 Phân tích và tạo kết quả có thể kiểm chứng 12
10.4 Tuần 4 Streaming và điều phối quy trình 12
10.5 Tuần 5 Tích hợp sản phẩm và chuẩn bị nộp bài 13
PHỤ LỤC CẬP NHẬT TIẾN ĐỘ VÀ NGUỒN NỘP BÀI 14

2 NGUỒN VÀ CẤU TRÚC DỮ LIỆU

Nguồn là Vietnamese E-commerce Review trên Kaggle, tác giả hienbm. File CSV đã được kiểm tra theo record có dấu nháy và xuống dòng; số dòng văn bản không được dùng thay số review.

Bảng 2: Quy mô và phạm vi nguồn

Chỉ số	Giá trị
Dung lượng	642.967.981 byte, khoảng 613,18 MiB
Record CSV	1.300.086
Khoảng thời gian	10/06/2013 đến 27/08/2022
Nền tảng	Shopee, Lazada, Sendo, Tiki
Trường quan sát chính	appid, reviewid, content, score, at

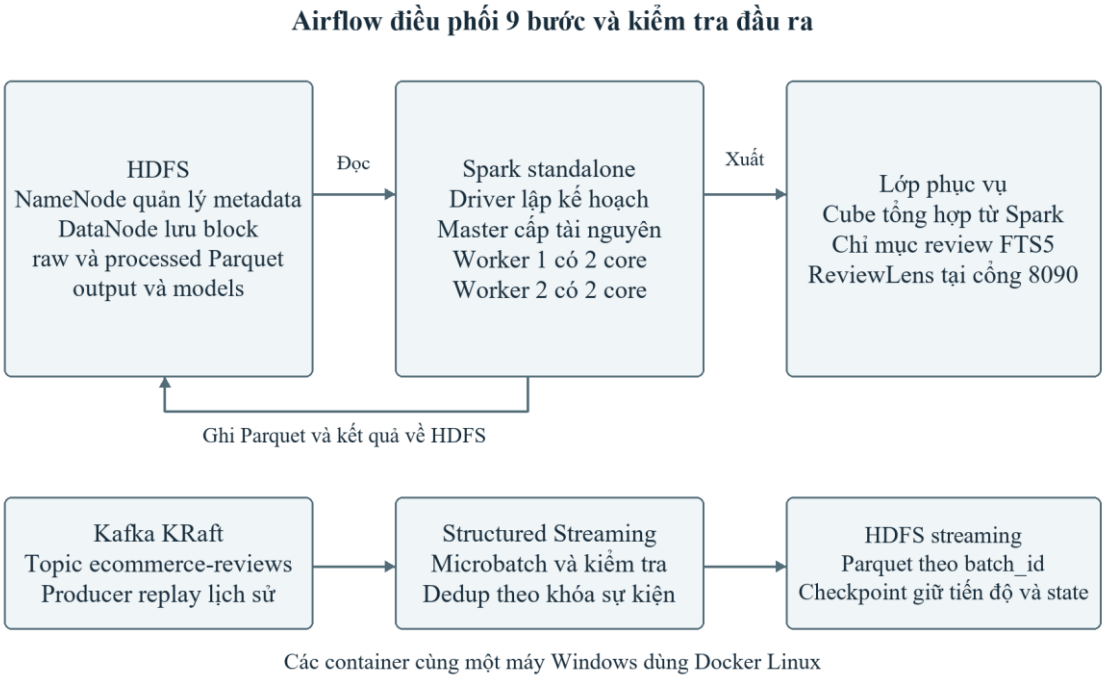
Bảng 3: Các trường CSV và cách sử dụng

Trường	Ý nghĩa và cách xử lý
csv_index	Index xuất CSV; không dùng làm khóa
reviewid và appid	Mã review và ứng dụng; kết hợp để khử trùng
username và userimage	Tên hiển thị và avatar; không chuyển sang processed
content	Văn bản phản hồi; giữ bản gốc và bản chuẩn hóa
score	Chuyển số nguyên; chỉ giữ mức sao 1-5
thumbsupcount	Lượt hữu ích; không xem là giá trị giao dịch
reviewcreatedversion	Phiên bản ứng dụng; chưa phân tích chính
at	Thời gian review; parse để tạo year/month
replycontent và repliedat	Phản hồi nhà phát triển; không ghép vào review

Nguồn: https://www.kaggle.com/datasets/hienbm/vietnamese-ecommerce-review; artifacts/audit/dataset_profile.json và outputs/raw_inspection.json.

Dữ liệu thiếu định danh khách hàng ổn định và giá trị đơn hàng, nên nhóm thay RFM bằng thống kê review và đề cập khía cạnh, đồng thời giữ K-Means để khám phá nội dung trong Spark MLlib.

3 KIẾN TRÚC HỆ THỐNG



Hình 1: Kiến trúc lưu trữ xử lý và phục vụ kết quả

Bảng 4: Vai trò và cấu hình thành phần

Thành phần	Cấu hình và trách nhiệm
HDFS	Hadoop 3.3.6; một NameNode, một DataNode; raw/processed/output/checkpoint
Spark	3.5.7 standalone; hai worker, mỗi worker 2 core; xử lý batch và streaming
Kafka	3.9.0 KRaft; một broker, topic ba partition; phát lại review lịch sử
Airflow	2.10.5 LocalExecutor; DAG chín task; PostgreSQL 16.6 lưu metadata
Lớp phục vụ	Cube tổng hợp Spark và SQLite FTS5 cho toàn bộ review đã làm sạch
ReviewLens	Python, HTML/CSS/JS; giao diện ở localhost:8090

Các container dùng chung một máy Windows. Replication HDFS bằng 1 và Kafka một broker phù hợp thực hành tại máy, chưa chứng minh khả năng chịu lỗi của cụm nhiều máy. SQLite là lớp tra cứu, còn HDFS là kho dữ liệu xử lý.

Nguồn: compose.yaml, infra/Dockerfile, infra/Dockerfile.airflow; docs/ARCHITECTURE.md.

4 NỘI DUNG ĐÃ TRIỂN KHAI

Bảng 5: Tiến độ theo chín bước thực hành

Bước	Thành phần	Kết quả và minh chứng
1	Chuẩn bị HDFS	Đã tạo vùng raw, processed, quarantine, output, models và checkpoints.
2	Upload dữ liệu	Raw giữ nguyên; kiểm tra fingerprint và năm block HDFS.
3	Đọc bằng Spark	Đọc đúng 1.300.086 record; schema rõ ràng và reader một partition.
4	Làm sạch	Cách ly 74 record, loại 139 bản sao ID; ghi Parquet theo platform/year.
5	Spark SQL	Thống kê theo sàn, tháng, sao và khía cạnh; lưu kế hoạch explain.
6	Khía cạnh và K-Means	Bảy khía cạnh theo luật; TF-IDF/K=8 trên 61.241 vector của mẫu hash.
7	Lưu và phục vụ	Kết quả HDFS; cube 1.910 ô và chỉ mục 1.299.873 review cùng generation.
8	Kafka ingest	Hai lượt replay tạo 2.000 offsets, HDFS giữ 1.000 review duy nhất.
9	Airflow DAG	Lần cơ bản 9/9 task success; task 07/09 mở rộng được kiểm tra riêng.

Pipeline kỹ thuật đã có đầu ra và kiểm chứng. Chất lượng nhận diện khía cạnh chưa được đánh giá bằng nhãn người đọc, nên nhóm chưa kết luận hoàn thành 100% mục tiêu phân tích.

Mã nguồn gồm jobs, src/review_analytics, config, dags, infra, scripts, tests và dashboard. Repository công khai DA_BIGDATA cung cấp source, README tái lập và minh chứng đã chọn: https://github.com/sangpm2005/DA_BIGDATA.

Nguồn: outputs/demo_evidence.json, outputs/dashboard_acceptance.json và mã nguồn trong thư mục dự án.

5 MINH CHỨNG HDFS VÀ XỬ LÝ BATCH

Bảng 6: Block thật của file raw HDFS

Block	Số byte	Replica
0	134.217.728	1
1	134.217.728	1
2	134.217.728	1
3	134.217.728	1
4	106.097.069	1

Lệnh fsck ghi HEALTHY, không có block thiếu hoặc hỏng. Tổng năm block là 642.967.981 byte; mọi block chỉ có một replica trên DataNode của máy thực hành.

Bảng 7: Đối soát số dòng sau làm sạch

Thành phần	Số record	Diễn giải
Raw	1.300.086	Khớp audit độc lập và count Spark
Quarantine	74	72 rỗng sau chuẩn hóa và 2 sao bằng 0
Bản sao ID	139	Loại theo khóa appid/reviewid
Processed	1.299.873	Có 1.299.873 khóa duy nhất khi đọc lại HDFS

Phương trình đối soát: 1.300.086 = 74 + 139 + 1.299.873. Review khác ID có cùng nội dung được giữ; tên hiển thị và avatar được bỏ khỏi tập phân tích.

CSV có trường nhiều dòng được đọc bằng một partition trước khi repartition(8). Năm block HDFS không tự tạo năm task parse CSV. Parquet theo platform/year hỗ trợ lọc partition; kế hoạch SQL có PartitionFilters, ReadSchema và Exchange để quan sát lượng cột đọc cùng shuffle.

Minh chứng: outputs/logs/hdfs_blocks.txt; outputs/data_quality.json; outputs/persisted_validation.json; outputs/spark_query_plan.txt. Mã xử lý: jobs/batch_pipeline.py và src/review_analytics/spark_ops.py.

6 MINH CHỨNG KAFKA VÀ AIRFLOW

Bảng 8: Hai lượt replay và checkpoint

Chỉ số	Kết quả
Review được phát lại mỗi lượt	1.000, cùng ID ổn định
Tổng end offsets sau hai lượt	2.000; partition 0/1/2 là 662/698/640
Review mới theo microbatch	499, 498, 3, 0, 0, 0
Dữ liệu streaming HDFS	1.000 dòng và 1.000 khóa duy nhất

Lượt replay sau không tạo review mới. Checkpoint giữ tiến độ Kafka và state chống trùng qua khởi động lại. State không watermark phù hợp demo hữu hạn; nhóm chưa xem đây là thiết kế streaming dài hạn đã hoàn thiện.

Bảng 9: Chín task trong DAG validation_20261012

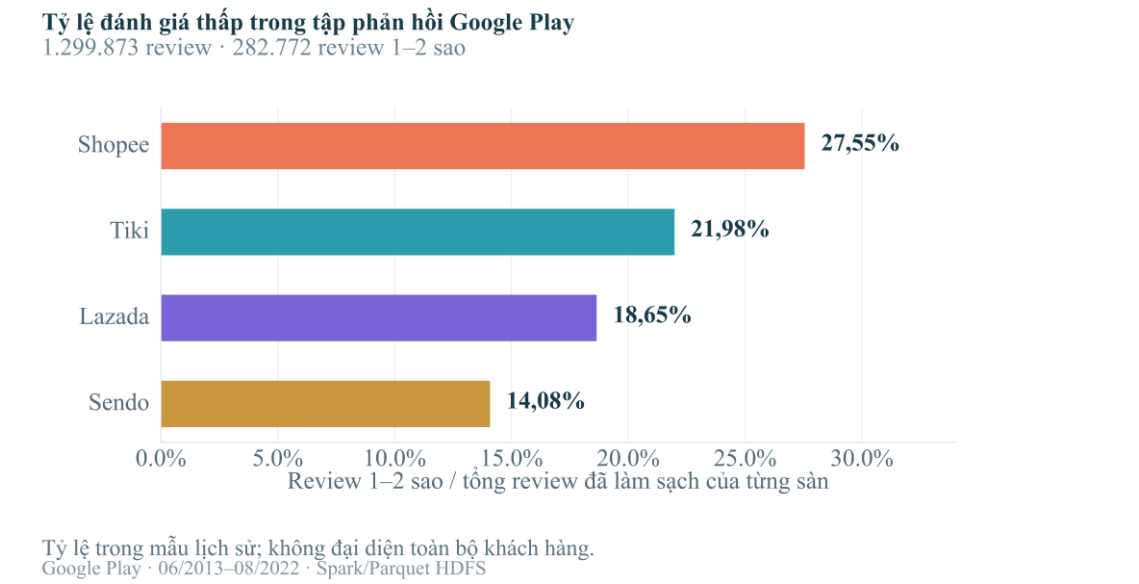
Bước	Task ID	Trạng thái
1	01_prepare_hdfs	Success
2	02_upload_csv	Success
3	03_read_with_spark	Success
4	04_clean_to_parquet	Success
5	05_spark_sql	Success
6	06_review_aspects_and_kmeans	Success
7	07_save_results	Success
8	08_kafka_replay_and_stream	Success
9	09_verify_completion	Success

Minh chứng: outputs/demo_evidence.json, outputs/stream_batch_0.json đến stream_batch_5.json; log task 07/09 mở rộng. Cả hai task mở rộng đã chạy thành công riêng sau khi bổ sung lớp phục vụ; không cộng các lần khác nhau thành một benchmark.

7 KẾT QUẢ PHÂN TÍCH HIỆN TẠI

Bảng 10: Review sau làm sạch theo nền tảng

Nền tảng	Review	Review 1-2 sao	Tỷ lệ
Shopee	519.191	143.040	27,55%
Lazada	530.404	98.905	18,65%
Sendo	179.632	25.299	14,08%
Tiki	70.646	15.528	21,98%
Toàn tập	1.299.873	282.772	21,75%



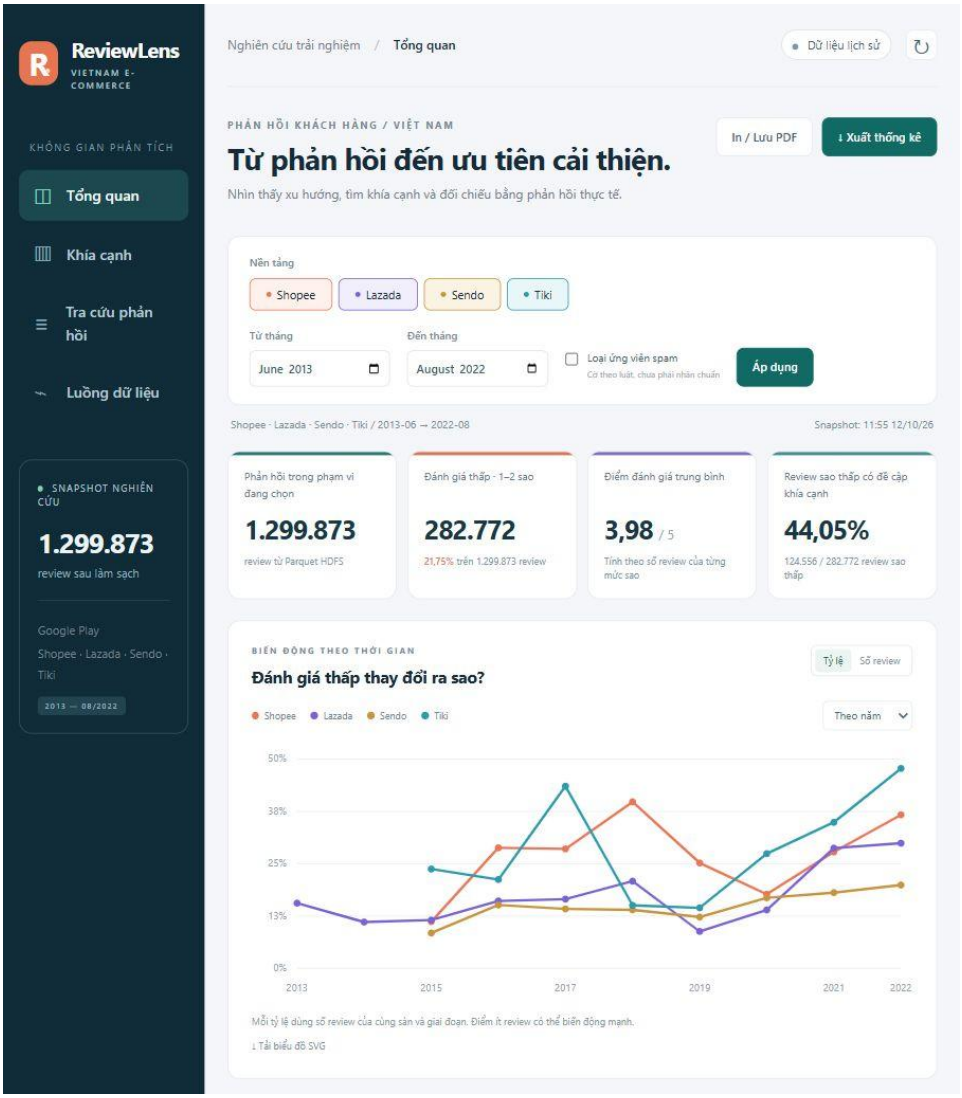
Hình 2: Tỷ lệ review sao thấp theo nền tảng

Bộ luật gán ít nhất một đề cập cho 124.556 review sao thấp, đạt 44,05%; còn 158.216 chưa gán. Ba khía cạnh có số đề cập lớn nhất là ứng dụng 57.454, vận chuyển 41.190 và sản phẩm 21.123. Review có thể nhắc nhiều khía cạnh, nên các số đếm này không cộng thành số người dùng.

K-Means chạy K=8 trên mẫu hash 25% đủ điều kiện, với 61.241 vector khác 0. Silhouette lần qua Airflow khoảng 0,0191 cho thấy phân tách còn yếu; không phải độ chính xác khía cạnh. Các nhận định về nguyên nhân cần kiểm tra thêm văn bản và dữ liệu vận hành.

Nguồn: outputs/platform_summary.csv, outputs/dashboard_cube.csv, outputs/cluster_metadata.json và outputs/dashboard_acceptance.json.

8 SẢN PHẨM REVIEWLENS VÀ KIỂM TRA HIỆN TẠI



Hình 3: Giao diện Tổng quan và biểu đồ ReviewLens

Ảnh giao diện từ snapshot kiểm chứng ngày 12/10/2026. Ảnh sản phẩm, biểu đồ và các phép đối soát được lưu trong repository; ngày của ảnh được giữ nguyên.

Bốn màn hình gồm Tổng quan, Khía cạnh, Tra cứu phản hồi và Luồng dữ liệu. Bộ lọc sàn/tháng thay đổi đúng mẫu số; tra cứu đọc toàn bộ 1.299.873 review từ chỉ mục. Sản phẩm cho xuất thống kê CSV, review theo bộ lọc và biểu đồ SVG.

ReviewLens phục vụ biểu đồ và tra cứu từ snapshot đã chuẩn bị. Đối soát ngày 15/10 xác nhận index có 1.299.873 review và 1.910 nhóm với chín số đếm khớp cube Spark; ảnh và số liệu không được dùng thay cho kiểm tra dịch vụ trực tiếp tại ngày nộp.

Minh chứng bổ sung: outputs/dashboard_validation.json ngày 15/10/2026, generation 3803e26d88584384995a5fdbcf9fa37a. Bản đối soát HDFS hiện lưu có 12 microbatch, trong đó chín batch không thêm ID mới; streaming vẫn có 1.000 dòng và khóa duy nhất.

9 KHÓ KHĂN PHẦN CHƯA HOÀN THÀNH VÀ KẾ HOẠCH TIẾP

Bảng 11: Khó khăn đã gặp và cách xử lý

Vấn đề	Cách xử lý và bằng chứng
CSV nhiều dòng	Dùng reader multiLine; count khớp audit rồi mới chia partition.
Trống sau Unicode	Giữ riêng số rỗng raw và sau chuẩn hóa; giải thích 71 thành 72.
Quyền ghi Spark/Airflow	Dùng tệp tạm và thay thế nguyên tử; tiếp tục từ task lỗi.
Tra cứu qua ổ Windows	Cache volume Linux khi chạy Docker; dùng FTS5 và kiểm tra generation.
Cube và chỉ mục có thể lệch	Đối soát mọi ô; 1.910 ô x 9 số đếm đều khớp.
Kết nối môi trường thực hành	Ngày 15/10 xử lý kiểm tra Engine trên PowerShell 5.1; giữ dữ liệu và checkpoint. Trạng thái ngày nộp cần kiểm tra riêng.

9.1 Phần chưa hoàn thành

Bộ mẫu 1.000 review chưa có nhãn người đọc. Nhóm cần gán nhãn độc lập theo đề cập và cảm xúc tại khía cạnh, kiểm tra lỗi bỏ sót rồi mới báo cáo precision, recall hoặc F1. Phần chưa gán 55,95% review sao thấp cần được rà soát, không được mặc định là không có vấn đề.

Chưa có benchmark lặp lại nhiều máy, thử mất node, nguồn review mới liên tục hoặc state retention cho streaming dài hạn. Dữ liệu là snapshot đến 08/2022; chưa tích hợp đơn hàng/log vận hành để xác minh nguyên nhân.

9.2 Kế hoạch hoàn thiện

Nhóm ưu tiên gán nhãn mẫu độc lập, cải thiện luật từ lỗi quan sát được và mở rộng kiểm tra khôi phục. Mã nguồn, hướng dẫn chạy và minh chứng được tổ chức trên repository DA_BIGDATA; báo cáo cuối kỳ trình bày đầy đủ thiết kế, triển khai, kết quả và các giới hạn còn lại.

13 bài kiểm tra tự động đã đạt ở lần kiểm chứng ngày 12/10/2026. Chúng kiểm tra logic dữ liệu và lớp phục vụ, không thay thế đánh giá chất lượng nhãn khía cạnh.

10 PHÂN CÔNG VÀ LỘ TRÌNH TRONG NĂM TUẦN

Nhóm tổ chức năm tuần theo mốc tương đối. Mỗi thành viên phụ trách một gói chính và một lượt rà soát chéo mỗi tuần, tổng năm gói/người. Tỷ trọng phân công dự kiến bằng nhau, mỗi người 1/3; không dùng tỷ trọng này làm số giờ hoặc mức đóng góp đã xác nhận.

10.1 Tuần 1 Khảo sát bài toán và chuẩn bị môi trường

Bảng 12: Phân công tuần 1

Thành viên	Công việc chính	Đầu ra kiểm chứng
Huỳnh Quang Sang	Xác định câu hỏi phân tích, phạm vi và chỉ số sao thấp.	Đề cương, định nghĩa mẫu số và giới hạn dữ liệu.
Phan Đức Thể	Khảo sát schema CSV, số record, dữ liệu rỗng và trùng.	Script audit, hồ sơ dữ liệu và SHA-256.
Đỗ Trọng Vĩ	Chuẩn bị Docker Compose, HDFS và Spark hai worker.	Cấu hình dịch vụ, ảnh worker và kiểm tra HDFS.

10.2 Tuần 2 Lưu trữ và làm sạch dữ liệu bằng Spark

Bảng 13: Phân công tuần 2

Thành viên	Công việc chính	Đầu ra kiểm chứng
Huỳnh Quang Sang	Tạo vùng HDFS, upload raw và kiểm tra block.	Script bootstrap, log fsck và fingerprint nguồn.
Phan Đức Thể	Đọc CSV nhiều dòng, chuẩn hóa và tách quarantine.	Job PySpark, reason lỗi và số đếm raw/quarantine.
Đỗ Trọng Vĩ	Khử trùng ID, ghi Parquet và đối soát số dòng.	Window dedup, partition platform/year và kiểm tra khóa.

Rà soát chéo: Sang kiểm tra gói của Thể; Thể kiểm tra gói của Vĩ; Vĩ kiểm tra gói của Sang. Tuần 1 và Tuần 2 chốt hợp đồng dữ liệu và đối soát nguồn trước khi phân tích.

10.3 Tuần 3 Phân tích và tạo kết quả có thể kiểm chứng

Bảng 14: Phân công tuần 3

Thành viên	Công việc chính	Đầu ra kiểm chứng
Huỳnh Quang Sang	Thực hiện Spark SQL theo sàn, thời gian và số sao.	Bảng thống kê, mẫu số và kế hoạch explain.
Phan Đức Thể	Xây luật đề cập bảy khía cạnh và kiểm tra phần chưa gán.	Cấu hình luật, bảng đề cập và độ bao phủ.
Đỗ Trọng Vĩ	Triển khai TF-IDF và K-Means trên mẫu hash.	Mô hình HDFS, metadata, từ khóa cụm và silhouette.

10.4 Tuần 4 Streaming và điều phối quy trình

Bảng 15: Phân công tuần 4

Thành viên	Công việc chính	Đầu ra kiểm chứng
Huỳnh Quang Sang	Tạo Kafka topic và producer phát lại review có ID ổn định.	Ba partition, log producer và end offsets.
Phan Đức Thể	Triển khai Structured Streaming, checkpoint và thử replay.	Metric microbatch, state dedup và 1.000 khóa duy nhất.
Đỗ Trọng Vĩ	Tạo DAG Airflow, kiểm tra phụ thuộc, retry và quyền ghi.	DAG, trạng thái chín task và log khôi phục.

Tiêu chí cuối Tuần 3 là thống kê có mẫu số, giải thích được kế hoạch SQL và công khai giới hạn khía cạnh/K-Means. Tiêu chí cuối Tuần 4 là replay giữ số unique, checkpoint có tiến độ/state và DAG có log để xác định task thất bại.

Các đầu ra kỹ thuật nêu trong phần tiến độ đã có minh chứng lưu. Bảng phân công xác định người chịu trách nhiệm triển khai, rà soát và giải thích từng gói trong kế hoạch năm tuần; không thay thế nhật ký làm việc cá nhân.

10.5 Tuần 5 Tích hợp sản phẩm và chuẩn bị nộp bài

Bảng 16: Phân công tuần 5

Thành viên	Công việc chính	Đầu ra kiểm chứng
Huỳnh Quang Sang	Tạo cube, chỉ mục tìm kiếm và đối soát lớp phục vụ.	Cube 1.910 ô, chỉ mục toàn tập và kiểm tra generation.
Phan Đức Thể	Hoàn thiện biểu đồ, bộ lọc, tra cứu và kiểm thử sản phẩm.	ReviewLens, ảnh giao diện và kiểm tra xuất CSV/SVG.
Đỗ Trọng Vĩ	Tổng hợp báo cáo, minh chứng, mã nguồn và kịch bản demo.	PDF tiến độ, ZIP source, hướng dẫn chạy và danh sách nộp.

Bảng 17: Cân bằng khối lượng theo kế hoạch

Thành viên	Gói chính	Rà soát chéo	Tỷ trọng
Huỳnh Quang Sang	5	5	1/3
Phan Đức Thể	5	5	1/3
Đỗ Trọng Vĩ	5	5	1/3

Cuối mỗi tuần, nhóm đối chiếu đầu ra với tiêu chí, kiểm tra chéo code/kết quả và cùng giải thích cơ chế Bigdata. Nếu một gói phát sinh lỗi hạ tầng hoặc xử lý phức tạp, nhóm điều chỉnh phần hỗ trợ để giữ khối lượng cân bằng; không chỉ chia theo số dòng code hoặc số trang báo cáo.

Bài nộp tiến độ gồm PDF này và mô tả có link repository. Mã nguồn, cấu hình, hướng dẫn tái lập và minh chứng được cung cấp trong repository; CSV gốc, chỉ mục SQLite, Docker volumes và cấu hình mật khẩu cục bộ không đưa lên Git.

Nguồn dữ liệu: Kaggle hienbm, Vietnamese E-commerce Review. Minh chứng kỹ thuật: các JSON, CSV tổng hợp và log trong repository. Các tuần là kế hoạch phân công tương đối, chưa gán ngày bắt đầu hoặc hồi tố thành lịch sử năm tuần đã làm việc.

PHỤ LỤC CẬP NHẬT TIẾN ĐỘ VÀ NGUỒN NỘP BÀI

Bảng tiến độ năm tuần ở trên là phân công cân bằng, không phải bảng chấm công hoặc lịch sử commit. Các kết quả kỹ thuật được dẫn theo đúng mốc thực nghiệm; các tuần là mốc tương đối.

Bảng PL.1 Các nội dung cập nhật sau mốc minh chứng ban đầu

Nội dung	**Kết quả đã lưu**
Đối soát bổ sung 15/10	HDFS processed 1.299.873 dòng/khóa; streaming 1.000 dòng/khóa, 12 microbatch.
Snapshot sản phẩm 15/10	Generation 3803e26d88584384995a5fdbcf9fa37a; 1.910 nhóm x 9 số đếm khớp toàn index.
Phân cụm bổ sung	K=8; 61.241 vector, mẫu hash 25%; silhouette khoảng 0,0200, không phải accuracy.
Nguồn nộp bài	https://github.com/sangpm2005/DA_BIGDATA
Việc còn lại	Gán nhãn người đọc; đánh giá khía cạnh; tích hợp nguồn mới và cập nhật sản phẩm từ streaming.

Repository được khởi tạo khi chuẩn bị nộp bài ngày 28/10/2026. Không có lịch sử commit của giai đoạn triển khai trước đó; nhóm không tạo lùi ngày hoặc gán commit thay cho thành viên. Nhật ký kỹ thuật được đối chiếu bằng log và artifact có sẵn.

Các phần đã hoàn thành là pipeline kỹ thuật, kiểm chứng số đếm và sản phẩm quan sát lịch sử. Chất lượng nhận diện khía cạnh vẫn ở mức baseline; chưa có precision, recall hoặc F1 trên tập nhãn độc lập.