BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HCM
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO CUỐI KỲ MÔN BIGDATA

PHÁT HIỆN CÁC KHÍA CẠNH GÂY KHÔNG HÀI LÒNG CỦA KHÁCH HÀNG TỪ DỮ LIỆU PHẢN HỒI TRÊN CÁC SÀN THƯƠNG MẠI ĐIỆN TỬ TẠI VIỆT NAM

Môn học: Bigdata

Bổ sung minh chứng ngày 29/10/2026

SINH VIÊN THỰC HIỆN
2001230757 - Huỳnh Quang Sang - 14DHTH13
2001230915 - Phan Đức Thể - 14DHTH13
2001231033 - Đỗ Trọng Vĩ - 14DHTH06

TP. HỒ CHÍ MINH, tháng 10 năm 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HCM
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO CUỐI KỲ MÔN BIGDATA

PHÁT HIỆN CÁC KHÍA CẠNH GÂY KHÔNG HÀI LÒNG CỦA KHÁCH HÀNG TỪ DỮ LIỆU PHẢN HỒI TRÊN CÁC SÀN THƯƠNG MẠI ĐIỆN TỬ TẠI VIỆT NAM

Môn học: Bigdata

Bổ sung minh chứng ngày 29/10/2026

GIẢNG VIÊN HƯỚNG DẪN
TS. Huỳnh Thái Học

SINH VIÊN THỰC HIỆN
2001230757 - Huỳnh Quang Sang - 14DHTH13
2001230915 - Phan Đức Thể - 14DHTH13
2001231033 - Đỗ Trọng Vĩ - 14DHTH06

TP. HỒ CHÍ MINH, tháng 10 năm 2026

HỒ SƠ MINH CHỨNG THỰC THI

Nhóm đã triển khai luồng CSV - HDFS - Spark SQL - Parquet - Kafka replay - Airflow và sản phẩm ReviewLens. Phần này trích mã nguồn, output, log và ảnh ngay trong PDF để có thể kiểm tra kết quả trước khi đọc các chương phân tích và thiết kế.

Repository công khai: https://github.com/sangpm2005/DA_BIGDATA

Mã nguồn và log trong hồ sơ được dẫn đến bản cố định 1f69ccf ngày 28/10/2026. Ngày 29/10 là ngày bổ sung cách trình bày; nhóm không chạy lại toàn hệ thống hoặc tạo lại ảnh giao diện trong lần sửa báo cáo này.

Bảng MC.1 Chỉ dẫn kiểm chứng trực tiếp trong tài liệu

Yêu cầu	Bằng chứng được nhúng	Trang
HDFS và ingestion	Mã tạo vùng, upload, fsck HEALTHY, 5 block	Xem ii
Spark xử lý	Hàm đọc CSV, mã ghi Parquet và cân bằng số dòng	Xem iii
Spark SQL	Truy vấn, bốn dòng kết quả và kế hoạch Parquet	Xem iv
Phân tích dữ liệu	Biểu đồ, mẫu số và kết luận có giới hạn	Xem v
Khía cạnh và K-Means	Heatmap, độ bao phủ và silhouette	Xem vi
Kafka và streaming	Mã checkpoint, offset, microbatch, khóa duy nhất	Xem vii
Airflow	Trích DAG, 9 task success và log exit code 0	Xem viii
Dashboard	Ảnh ReviewLens và đối soát cube với chỉ mục	Xem ix
Khả năng tái lập	Lệnh chạy, README, commit và nhật ký lỗi	Xem x

Kết quả tổng quát

Nguồn 1.300.086 record, 642.967.981 byte; processed 1.299.873 review; cách ly 74 dòng; loại 139 bản sao ID. Có 282.772 review 1-2 sao, tương đương 21,75%. Hai lượt replay ban đầu có tổng end offsets 2.000 nhưng HDFS chỉ giữ 1.000 khóa streaming duy nhất.

Minh chứng chính ngày 12/10 và đối soát bổ sung ngày 15/10 được ghi riêng. Bài toán là phân tích phản hồi Google Play về ứng dụng TMĐT; chưa có nhãn độc lập để khẳng định độ chính xác nhận diện khía cạnh.

MINH CHỨNG HDFS VÀ ĐƯA DỮ LIỆU VÀO HỆ THỐNG

Mã đã triển khai

```
def prepare():
    hdfs("-mkdir", "-p", *[f"{BASE}/{zone}" for zone in
        ["raw", "processed", "output", "quarantine", "models", "checkpoints",
            "streaming"]])
```

Mở đối chiếu: scripts/bootstrap_hdfs.py dòng 16-18

```
    if exists:
        stored = hdfs("-cat", manifest, check=False, capture=True)
        if stored.returncode != 0 or stored.stdout.strip() != fingerprint:
            raise ValueError("HDFS raw already exists with a different or
            missing fingerprint; use a versioned raw path")
        print("Source already uploaded with matching SHA-256", flush=True)
        return
    hdfs("-put", str(source), destination)
```

Mở đối chiếu: scripts/bootstrap_hdfs.py dòng 30-36

Upload kiểm tra fingerprint trước khi ghi; nếu raw đã tồn tại với SHA-256 khớp thì bỏ qua. Nguồn khác cần đường dẫn có phiên bản. Các đoạn mã được trích từ source và ngắt dòng dài để đọc; mở link để xem bản đầy đủ. Manifest nguồn không thay thế việc xác minh byte toàn HDFS.

Lệnh kiểm tra tương ứng

```
docker compose exec -T namenode hdfs dfs -ls /ecommerce/raw
docker compose exec -T namenode hdfs fsck /ecommerce/raw/reviews.csv -files
    -blocks -locations
```

Trích log thực thi đã lưu

```
/ecommerce/raw/reviews.csv 642967981 bytes, replicated: replication=1, 5
    block(s):  OK
Status: HEALTHY
 Total blocks (validated):   5 (avg. block size 128593596 B)
 Missing blocks:             0
 Corrupt blocks:             0
```

Mở đối chiếu: Log fsck đầy đủ có vị trí của từng block

Log bắt đầu 11/10/2026 20:02 UTC, tương đương 12/10/2026 03:02 giờ Việt Nam. File có đúng 642.967.981 byte, năm block, không thiếu hoặc hỏng block. Một DataNode và replication=1 phù hợp mô hình thực hành; chưa chứng minh chịu lỗi khi mất máy.

MINH CHỨNG ĐỌC VÀ LÀM SẠCH BẰNG SPARK

```
def read_raw(spark, path: str) -> DataFrame:
    return (spark.read.schema(RAW_SCHEMA).option("header", True)
        .option("multiLine", True).option("quote", '"').option("escape", '"')
        .option("mode", "PERMISSIVE").option("enforceSchema", True)
        .option("columnNameOfCorruptRecord", "_corrupt_record").csv(path))
```

Mở đối chiếu: src/review_analytics/spark_ops.py dòng 21-25

Đầu vào thực tế là hdfs://namenode:9000/ecommerce/raw/reviews.csv. multiLine giữ đúng record có xuống dòng trong nội dung. Kiểm tra đọc xác nhận Spark 3.5.7, 1.300.086 record và reader_partitions=1; nhóm repartition sau đọc, không nhầm năm block HDFS thành năm task CSV.

```
    valid = prepared.filter(F.size("validation_reasons") == 0)
    cleaned =

analytical_columns(deduplicate_valid(valid)).persist(StorageLevel.MEMORY_AND_DISK)
    clean_n = cleaned.count()
    duplicates_n = raw_n - invalid_n - clean_n
    cleaned.repartition(args.partitions, "platform",
        "year").write.mode("overwrite") \
        .partitionBy("platform",
            "year").parquet(f"{args.root}/processed/reviews")
```

Mở đối chiếu: jobs/batch_pipeline.py dòng 53-58

Output chất lượng dữ liệu từ data_quality.json


```
{
  "raw_rows": 1300086,
  "quarantined_rows": 74,
  "clean_rows": 1299873,
  "duplicate_valid_id_rows_removed": 139,
  "row_balance_ok": true,
  "output_partitions": 8,
  "partition_columns": [
    "platform",
    "year"
  ]
}
```


Mở đối chiếu: evidence/verified_20261028/data_quality.json

Đối chiếu: 1.300.086 = 74 + 139 + 1.299.873. Trong vùng cách ly có 72 dòng thiếu nội dung và hai dòng score không hợp lệ. Dữ liệu hợp lệ được dedup theo appid/reviewid, giữ các review khác ID dù nội dung lặp.

Mở đối chiếu: Log Spark đầy đủ có kết nối cluster, hai executor RUNNING và output inspect/clean

Mở đối chiếu: Output đọc CSV từ HDFS và đối chiếu audit

MINH CHỨNG SPARK SQL VÀ KẾT QUẢ TRUY VẤN

```
    reviews = spark.read.parquet(f"{args.root}/processed/reviews")
    reviews.createOrReplaceTempView("reviews")
    tables = {
        "platform_summary": spark.sql("""
            SELECT platform, COUNT(*) AS reviews, AVG(score) AS mean_rating,
                   SUM(CASE WHEN low_rating_proxy THEN 1 ELSE 0 END) AS
            low_rating_reviews,
                   AVG(CASE WHEN low_rating_proxy THEN 1.0 ELSE 0.0 END) AS
            low_rating_rate,
                   SUM(CASE WHEN spam_candidate THEN 1 ELSE 0 END) AS
            spam_candidate_reviews
            FROM reviews GROUP BY platform ORDER BY platform
        """),
```

Mở đối chiếu: jobs/batch_pipeline.py dòng 73-82

Bảng MC.2 Bốn dòng kết quả thực tế trong platform_summary.csv

Nền tảng	Review	Sao thấp	Tỷ lệ sao thấp
Lazada	530.404	98.905	18,65%
Sendo	179.632	25.299	14,08%
Shopee	519.191	143.040	27,55%
Tiki	70.646	15.528	21,98%

Mở đối chiếu: evidence/verified_20261028/platform_summary.csv

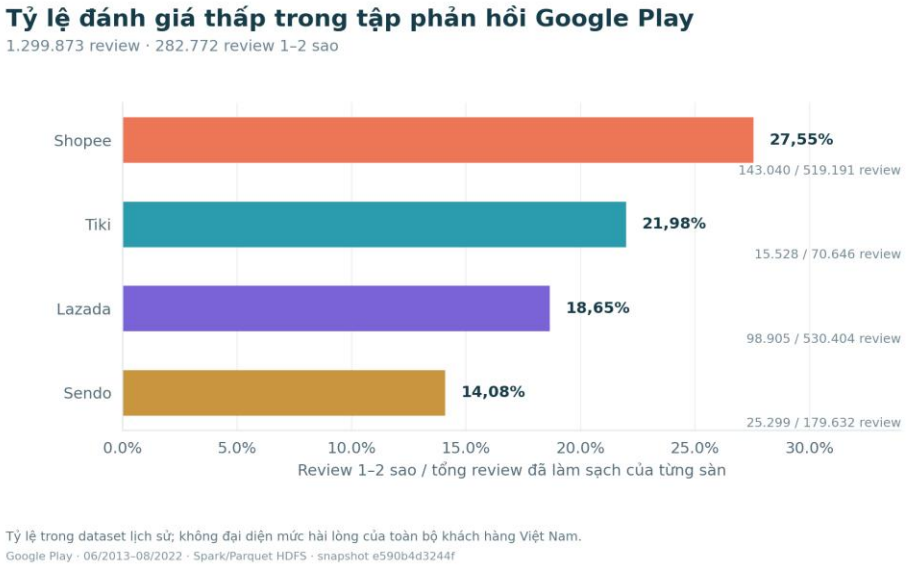
Kế hoạch vật lý của truy vấn lọc Shopee năm 2022

```
+- Exchange hashpartitioning(platform#9, month#5, 8), ENSURE_REQUIREMENTS,
    [plan_id=1021]
PartitionFilters: [isnotnull(platform#9), isnotnull(year#10), (platform#9 =
    Shopee), (year#10 = 2022)]
ReadSchema: struct<month:string>
```

Mở đối chiếu: evidence/verified_20261028/spark_query_plan.txt

Exchange thể hiện shuffle để tổng hợp theo nhóm. PartitionFilters giới hạn platform và year; ReadSchema chỉ cần cột month từ file cho truy vấn này. Đây là bằng chứng pruning và đọc theo cột; chưa phải benchmark chứng minh tăng tốc bao nhiêu lần.

MINH CHỨNG BIỂU ĐỒ VÀ KẾT LUẬN PHÂN TÍCH



Hình MC.1 Tỷ lệ review 1-2 sao và quy mô quan sát theo nền tảng

Nguồn: platform_summary.csv do Spark SQL xuất từ processed Parquet trên HDFS. Biểu đồ đã có trong thực nghiệm ngày 12/10; không phải ảnh mới tạo từ một lần chạy ngày 29/10.

Kết quả và cách sử dụng

Trong tập quan sát, Shopee có 143.040/519.191 review sao thấp (27,55%), cao hơn Lazada 18,65%, Sendo 14,08% và Tiki 21,98%. Tiki có 70.646 review, ít hơn các nền tảng khác, nên cần giữ mẫu số khi so sánh.

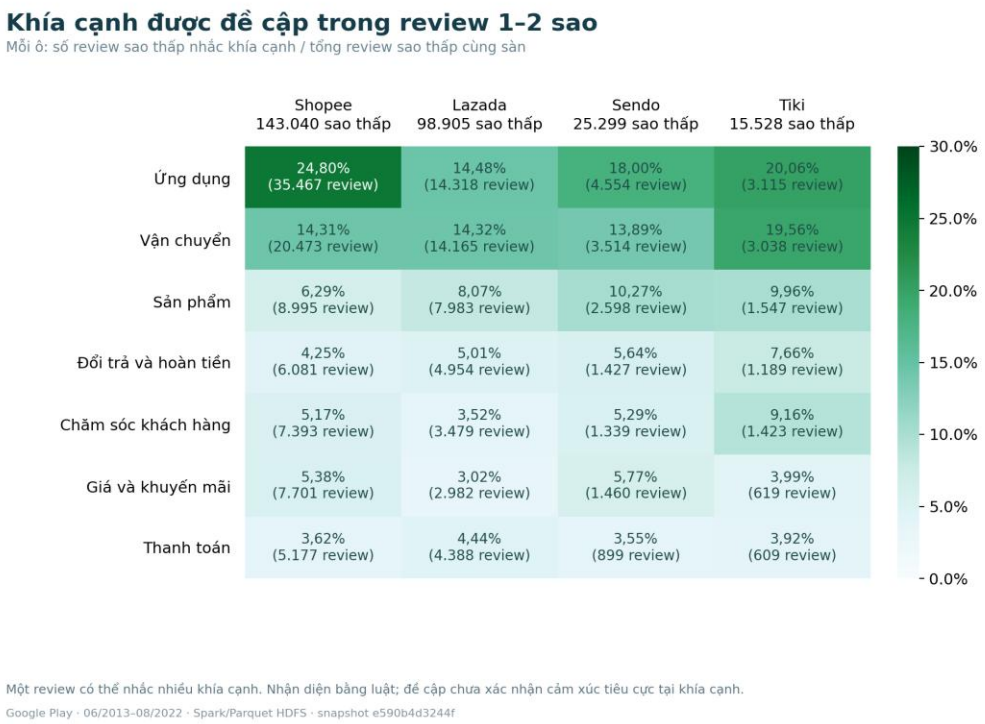
Kết quả giúp chọn nền tảng và giai đoạn cần rà soát trước, sau đó dùng bộ lọc khía cạnh và tra cứu phản hồi để xem ngữ cảnh. Chênh lệch tỷ lệ trên Google Play không đủ để xếp hạng chất lượng dịch vụ hoặc suy ra tỷ lệ không hài lòng của toàn bộ khách hàng.

Đối chiếu theo thời gian

Riêng Shopee giai đoạn 01/2021-08/2022 có 81.979/260.800 review sao thấp, tương đương 31,43%. Đây là lát cắt để đặt câu hỏi kiểm tra, chưa phải bằng chứng về một thay đổi sản phẩm cụ thể. Các biểu đồ xu hướng đầy đủ và phân tích giới hạn nằm tại Chương 5.

Mở đối chiếu: evidence/verified_20261028/monthly_summary.csv

MINH CHỨNG KHÍA CẠNH VÀ THÍ NGHIỆM K MEANS



Hình MC.2 Tỷ lệ đề cập khía cạnh trong nhóm review sao thấp

Trong 282.772 review sao thấp, có 124.556 review đề cập ít nhất một khía cạnh (44,05%); còn 158.216 review chưa khớp luật. Có 57.454 review đề cập ứng dụng và 41.190 đề cập vận chuyển. Một review có thể đề cập nhiều khía cạnh nên không cộng các hàng thành số khách hàng.

Đây là thống kê đề cập từ khóa trong nhóm sao thấp. Nhóm chưa gán nhãn để kiểm chứng một khía cạnh được nói theo hướng tích cực hay tiêu cực; chưa có precision, recall hoặc F1.

Metric K-Means đã lưu trong lần bổ sung ngày 15/10


```
{
  "k": 8,
  "seed": 42,
  "training_rows": 61241,
  "sample_percent": 25,
  "silhouette_sample_max": 10000,
  "silhouette_cosine": 0.02000751037862234
}
```


Mở đối chiếu: evidence/verified_20261028/cluster_metadata.json

Cosine silhouette 0,0200 cho thấy các cụm phân tách yếu. K-Means chỉ hỗ trợ khám phá từ khóa; không dùng chỉ số này làm accuracy hoặc chứng minh phân loại phàn nàn đúng. Hướng đáp ứng chính của đồ án là phân tích dữ liệu có số liệu và insight.

Mở đối chiếu: evidence/verified_20261028/aspect_mentions.csv

MINH CHỨNG KAFKA VÀ STRUCTURED STREAMING

Kafka mô phỏng đưa dữ liệu lịch sử vào topic ecommerce-reviews, ba partition. Producer tạo event_id ổn định; consumer giữ checkpoint trên HDFS và khử trùng bằng trạng thái. Đây là historical replay, không phải nguồn review trực tuyến mới.

```
events = (kafka.select(F.from_json(F.col("value").cast("string"),
    EVENT_SCHEMA).alias("event"),
    "topic", "partition", "offset").select("event.*", "topic", "partition",
        "offset")
    .withColumn("dedup_key", F.coalesce("event_id", F.concat_ws(":",
        "topic", "partition", "offset")))
    .dropDuplicates(["dedup_key"]))
```

Mở đối chiếu: jobs/stream_reviews.py dòng 34-37

```
writer = events.writeStream.foreachBatch(write_batch).option(
    "checkpointLocation", f"{args.root}/checkpoints/reviews-v1")
writer = writer.trigger(processingTime="10 seconds") if args.continuous else
    writer.trigger(availableNow=True)
```

Mở đối chiếu: jobs/stream_reviews.py dòng 59-61

Output producer và thử nghiệm replay ngày 12/10

```
{"published_events": 1000, "topic": "ecommerce-reviews", "mode":
    "historical_replay"}
```

Bảng MC.3 Offset và số ID mới trong hai lượt phát ban đầu

Đối tượng	Giá trị quan sát
End offset partition 0 / 1 / 2	662 / 698 / 640; tổng vị trí kế tiếp 2.000
new_unique_events của batch 0-5	499, 498, 3, 0, 0, 0
HDFS streaming rows / unique keys	1.000 / 1.000
Đối soát bổ sung ngày 15/10	12 batch; chín batch không thêm ID mới; vẫn 1.000 khóa

Mở đối chiếu: Metadata thử replay ban đầu, offset và HDFS

Mở đối chiếu: Đối soát HDFS bổ sung sau các lần replay

Consumer ghi Parquet theo batch_id và checkpoint ở /ecommerce/checkpoints/reviews-v1. Giữ nguyên checkpoint giúp nhận ra ID đã xử lý; xóa checkpoint làm thay đổi phép thử. foreachBatch có ngữ nghĩa at-least-once, không bảo đảm một giao dịch nguyên tử trên mọi output. Query chưa có watermark để giới hạn state.

MINH CHỨNG ĐIỀU PHỐI AIRFLOW

```
with DAG(
    dag_id="ecommerce_dissatisfaction_pipeline",
    description="HDFS, Spark SQL, aspect mentions, K-Means, Kafka historical
        replay",
    start_date=pendulum.datetime(2026, 10, 12, tz="Asia/Ho_Chi_Minh"),
    schedule=None, catchup=False, max_active_runs=1,
    default_args={"retries": 1, "retry_delay": timedelta(seconds=30),
        "execution_timeout": timedelta(minutes=40)},
```

Mở đối chiếu: dags/ecommerce_pipeline.py dòng 11-16

```
    prepare >> upload >> read >> clean >> sql >> clustering >> export >> kafka
        >> complete
```

Mở đối chiếu: dags/ecommerce_pipeline.py dòng 36-36

Bảng MC.4 Trạng thái chín task của run validation_20261012

Task	Trạng thái
01_prepare_hdfs	success
02_upload_csv	success
03_read_with_spark	success
04_clean_to_parquet	success
05_spark_sql	success
06_review_aspects_and_kmeans	success
07_save_results	success
08_kafka_replay_and_stream	success
09_verify_completion	success

Mở đối chiếu: Run ID, trạng thái và thời gian bắt đầu kết thúc từng task

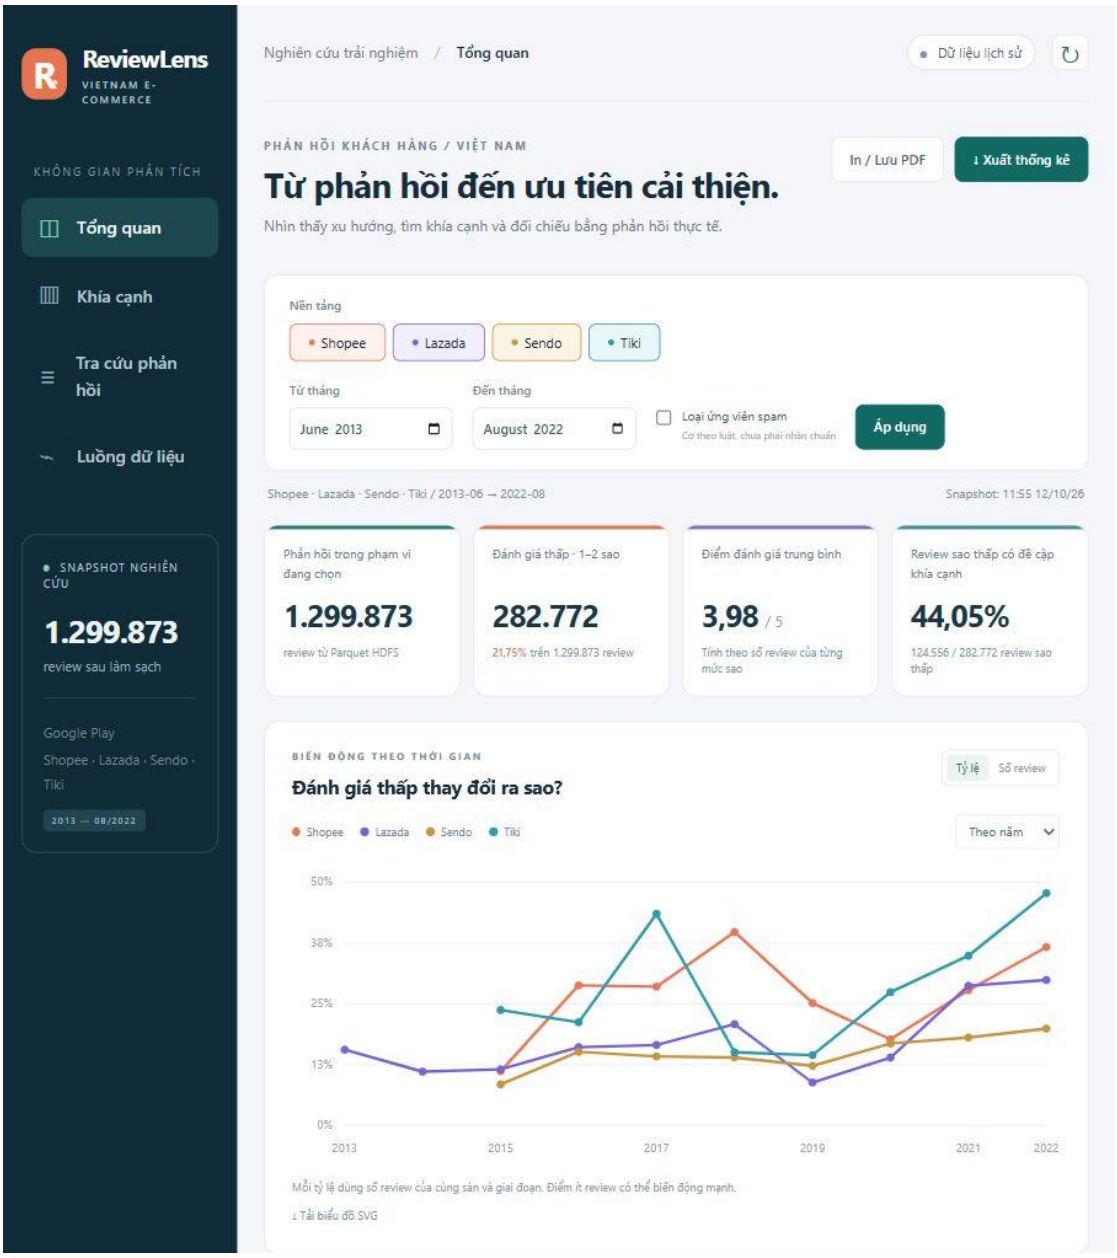
Trích log task 09 kiểm tra đầu ra mở rộng

```
[2026-10-12T05:13:45.803+0000] {subprocess.py:110} INFO - Command exited with
    return code 0
```

Mở đối chiếu: evidence/verified_20261028/logs/dashboard_airflow_task09.log

Run cơ bản có 9/9 task success. Task 07/09 được mở rộng cho cube và chỉ mục, có log chạy riêng cùng ngày; nhóm không gộp các lượt này thành một benchmark end-to-end duy nhất. retry=1, delay 30 giây, max_active_runs=1; lịch chạy bằng tay. DAG và log đầy đủ có thể mở bằng các link trên.

MINH CHỨNG GIAO DIỆN REVIEWLENS



Hình MC.3 Màn hình Tổng quan với bộ lọc chỉ số và biểu đồ xu hướng

Ảnh chụp snapshot ngày 12/10/2026, cắt phần đầu để đọc rõ. Toàn bộ ảnh và hai màn hình Khía cạnh, Luồng dữ liệu được lưu trong repository. Ảnh chứng minh sản phẩm đã hiển thị; không khẳng định dịch vụ đang chạy tại ngày sửa báo cáo.

Mở đối chiếu: Ba ảnh ReviewLens đầy đủ

Nguồn số liệu: HDFS processed - Spark tạo cube - xuất chỉ mục SQLite FTS5 - API - trình duyệt. Đối soát 15/10 xác nhận 1.299.873 review trong index và 1.910 nhóm x 9 số đếm khớp cube Spark; generation 3803e26d88584384995a5fdbcf9fa37a.

Mở đối chiếu: evidence/verified_20261028/dashboard_validation.json

Giao diện là đầu ra phân tích batch. Dữ liệu streaming được kiểm chứng ở vùng HDFS riêng, chưa cập nhật tự động vào dashboard. Mã giao diện và API nằm trong dashboard/, lớp chuẩn bị ở jobs/prepare_dashboard.py và scripts/build_dashboard_index.py.

MINH CHỨNG TÁI LẬP VÀ QUÁ TRÌNH THỰC HIỆN

Điều kiện và lệnh bắt đầu từ máy mới

```
git clone https://github.com/sangpm2005/DA_BIGDATA.git
cd DA_BIGDATA
.\scripts\Init-LocalConfig.ps1
# Tải CSV từ Kaggle và đặt tại thư mục gốc như README
docker compose build spark-client
docker compose up -d namenode datanode spark-master `
    spark-worker-1 spark-worker-2 spark-client
docker compose exec -T spark-client python scripts/bootstrap_hdfs.py
```

Thực hiện tiếp batch, Kafka, Airflow và sản phẩm theo RUNBOOK. Có thể kiểm tra nhanh bộ minh chứng bằng python scripts/check_submission_evidence.py mà chưa cần Docker. Lệnh này kiểm tra hash và số liệu đã lưu, không chạy lại pipeline. Cấu hình .env cục bộ không đưa lên Git.

Mở đối chiếu: README có nguồn dữ liệu cấu hình cách chạy và kết quả kỳ vọng

Mở đối chiếu: RUNBOOK gồm lệnh thực thi và kiểm tra theo từng bước

Bảng MC.5 Nhật ký lỗi và cách khắc phục có nguồn đối chiếu

Vấn đề	Thay đổi và kiểm tra
Khác UID giữa Spark và Airflow khi ghi artifact	Dùng file tạm và os.replace; tests_after_io_fix.log; task 07/09 có log thành công.
PowerShell 5.1 trả ExitCode null khi kiểm tra Docker	Dùng ProcessStartInfo, timeout và ExitCode thực; engine_probe.json 15/10 trả 0.
Rủi ro đếm từ cube khác phiên bản index	Dùng generation và audit toàn 1.910 nhóm x 9 số đếm, dừng nếu không khớp.

Mở đối chiếu: Nhật ký mốc có minh chứng và phân công cân bằng năm tuần

Lịch sử Git công khai đã có

```
5a79dfc Add Bigdata review pipeline with reproducible setup and verified
    evidence
c2bee46 Add final and progress PDFs with submission descriptions and complete
    evidence logs
1f69ccf Publish the two PDF reports and matching LMS descriptions
```

Mở lịch sử commit trên GitHub

Git khởi tạo ngày 28/10 khi đóng gói; ba commit trên không chứng minh đóng góp cá nhân hoặc toàn bộ quá trình trước đó. Kế hoạch năm tuần chia đều ba người là phân công trách nhiệm. Nhóm chưa có lịch sử commit trước ngày khởi tạo để xác nhận thực tế từng thành viên.

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn đến Khoa Công nghệ thông tin, Trường Đại học Công Thương TP. Hồ Chí Minh đã tạo điều kiện học tập và thực hành môn Bigdata.

Nhóm xin cảm ơn TS. Huỳnh Thái Học đã hướng dẫn nội dung môn học và định hướng luồng thực hành để nhóm xây dựng đồ án từ khảo sát dữ liệu đến lưu trữ, xử lý, kiểm chứng và trình bày kết quả.

Qua quá trình thực hiện, nhóm có điều kiện đối chiếu kiến thức về HDFS, Spark, Kafka và Airflow với dữ liệu phản hồi thực tế. Nhóm mong nhận được góp ý của giảng viên để tiếp tục hoàn thiện cách phân tích và những phần còn hạn chế của hệ thống.

Nhóm chúng em xin chân thành cảm ơn.

MỤC LỤC

HỒ SƠ MINH CHỨNG THỰC THI i
MINH CHỨNG HDFS VÀ ĐƯA DỮ LIỆU VÀO HỆ THỐNG ii
MINH CHỨNG ĐỌC VÀ LÀM SẠCH BẰNG SPARK iii
MINH CHỨNG SPARK SQL VÀ KẾT QUẢ TRUY VẤN iv
MINH CHỨNG BIỂU ĐỒ VÀ KẾT LUẬN PHÂN TÍCH v
MINH CHỨNG KHÍA CẠNH VÀ THÍ NGHIỆM K MEANS vi
MINH CHỨNG KAFKA VÀ STRUCTURED STREAMING vii
MINH CHỨNG ĐIỀU PHỐI AIRFLOW viii
MINH CHỨNG GIAO DIỆN REVIEWLENS ix
MINH CHỨNG TÁI LẬP VÀ QUÁ TRÌNH THỰC HIỆN x
LỜI CẢM ƠN xi
MỤC LỤC xii
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT xv
DANH MỤC HÌNH xvi
DANH MỤC BẢNG xvii
MỞ ĐẦU 1
1. GIỚI THIỆU ĐỀ TÀI 1
2. MỤC TIÊU ĐỀ TÀI 1
3. ĐỐI TƯỢNG VÀ PHẠM VI 2
4. PHƯƠNG PHÁP VÀ BỐ CỤC BÁO CÁO 2
CHƯƠNG 1 KHẢO SÁT BÀI TOÁN BIGDATA 3
1.1. BÀI TOÁN KHAI THÁC PHẢN HỒI 3
1.2. CÁCH HIỂU BIGDATA TRONG ĐỒ ÁN 3
1.3. LƯU TRỮ BẰNG HDFS 4
1.4. CƠ CHẾ XỬ LÝ CỦA SPARK 4
1.4.1. Driver worker và executor 4
1.4.2. Transformation action và shuffle 4
1.4.3. Parquet và truy vấn theo partition 5
1.5. KAFKA STRUCTURED STREAMING VÀ AIRFLOW 5
1.6. VAI TRÒ CỦA PHÂN TÍCH NỘI DUNG 5
CHƯƠNG 2 PHÂN TÍCH DỮ LIỆU VÀ YÊU CẦU 6
2.1. KHẢO SÁT NGUỒN DỮ LIỆU 6
2.1.1. Các trường dữ liệu 7
2.1.2. Ánh xạ nền tảng và đơn vị quan sát 8
2.2. PHÂN TÍCH CHẤT LƯỢNG VÀ QUY TẮC XỬ LÝ 8
2.2.1. Dữ liệu không hợp lệ và vùng cách ly 8
2.2.2. Khử trùng ID và nội dung lặp 8
2.2.3. Chuẩn hóa văn bản và cờ ứng viên spam 9

2.3. YÊU CẦU CHỨC NĂNG VÀ TIÊU CHÍ KIỂM CHỨNG 9
2.4. ĐIỀU CHỈNH LUỒNG THỰC HÀNH THEO ĐỀ TÀI 10
2.5. ĐỊNH NGHĨA CHỈ SỐ VÀ GIẢ THUYẾT PHÂN TÍCH 11
CHƯƠNG 3 THIẾT KẾ PIPELINE BIGDATA 12
3.1. KIẾN TRÚC TỔNG THỂ 12
3.2. TỔ CHỨC CÁC VÙNG DỮ LIỆU TRÊN HDFS 12
3.3. THIẾT KẾ HỢP ĐỒNG DỮ LIỆU 13
3.3.1. Hợp đồng processed 13
3.3.2. Hợp đồng sự kiện và thời gian 14
3.4. THIẾT KẾ XỬ LÝ BATCH VÀ SPARK SQL 15
3.5. THIẾT KẾ NHẬN DIỆN ĐỀ CẬP VÀ PHÂN CỤM 16
3.5.1. Bộ khía cạnh và phương pháp theo luật 16
3.5.2. Vector hóa và K-Means trong Spark 16
3.6. THIẾT KẾ STREAMING VÀ ĐIỀU PHỐI 18
3.7. THIẾT KẾ LỚP PHỤC VỤ REVIEWLENS 19
CHƯƠNG 4 TRIỂN KHAI VÀ KIỂM CHỨNG 20
4.1. MÔI TRƯỜNG VÀ CẤU TRÚC SOURCE 20
4.2. CHUẨN BỊ HDFS VÀ UPLOAD NGUỒN 20
4.3. ĐỌC CSV VÀ LÀM SẠCH BẰNG SPARK 21
4.3.1. Đọc đúng ranh giới record 21
4.3.2. Kiểm tra làm sạch và khử trùng 22
4.3.3. Ghi Parquet và tránh thu toàn bộ về driver 22
4.4. THỰC HIỆN SPARK SQL VÀ KIỂM TRA KẾ HOẠCH 23
4.5. THỰC HIỆN KHÍA CẠNH K MEANS VÀ LƯU KẾT QUẢ 23
4.6. THỰC NGHIỆM KAFKA VÀ CHECKPOINT 24
4.7. ĐIỀU PHỐI AIRFLOW VÀ ĐỐI SOÁT ĐẦU RA 25
4.8. KIỂM TRA TỰ ĐỘNG VÀ KHẢ NĂNG TÁI LẬP 26
CHƯƠNG 5 KẾT QUẢ VÀ SẢN PHẨM 28
5.1. KẾT QUẢ THỐNG KÊ SAU LÀM SẠCH 28
5.2. BIẾN ĐỘNG THEO THỜI GIAN 29
5.3. KHÍA CẠNH ĐƯỢC ĐỀ CẬP VÀ ĐỘ BAO PHỦ 30
5.4. KẾT QUẢ KHÁM PHÁ K MEANS 31
5.5. SẢN PHẨM QUAN SÁT REVIEWLENS 32
5.5.1. Các chức năng và nguồn số liệu 32
5.5.2. Tình huống sử dụng để rà soát trải nghiệm 34
5.5.3. Kiểm tra thao tác và thời gian truy vấn 34
5.6. ĐÁNH GIÁ THEO MỤC TIÊU BIGDATA 34
KẾT LUẬN 35
1. KẾT QUẢ ĐẠT ĐƯỢC 35
2. HẠN CHẾ 35

3. HƯỚNG PHÁT TRIỂN 35
TÀI LIỆU THAM KHẢO 37
PHỤ LỤC A ĐỐI CHIẾU YÊU CẦU VÀ MINH CHỨNG 38
PHỤ LỤC B ĐỐI SOÁT BỔ SUNG NGÀY 15 THÁNG 10 39
PHỤ LỤC C LỆNH CHẠY VÀ ĐIỀU KIỆN TÁI HIỆN 40
PHỤ LỤC D NHẬT KÝ KỸ THUẬT VÀ XỬ LÝ LỖI 41
PHỤ LỤC E PHÂN CÔNG CÂN BẰNG TRONG NĂM TUẦN 42
PHỤ LỤC E PHÂN CÔNG TUẦN BA ĐẾN TUẦN NĂM 43
PHỤ LỤC F ĐỐI CHIẾU MÃ NGUỒN VÀ KẾT QUẢ CHẠY 44

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
HDFS	Hadoop Distributed File System	Hệ thống file phân tán Hadoop
CSV	Comma Separated Values	Định dạng dữ liệu phân tách bằng dấu phẩy
SQL	Structured Query Language	Ngôn ngữ truy vấn có cấu trúc
DAG	Directed Acyclic Graph	Đồ thị có hướng không chu trình
RDD	Resilient Distributed Dataset	Tập dữ liệu phân tán có khả năng phục hồi
TF-IDF	Term Frequency Inverse Document Frequency	Trọng số tần suất và độ phổ biến của thuật ngữ
MLlib	Machine Learning Library	Thư viện học máy của Spark
RFM	Recency Frequency Monetary	Thời điểm tần suất và giá trị giao dịch
FTS	Full Text Search	Tìm kiếm toàn văn
CSKH	Customer Service	Chăm sóc khách hàng
API	Application Programming Interface	Giao diện lập trình ứng dụng
UID	User Identifier	Mã người dùng của hệ điều hành

DANH MỤC HÌNH

Hình MC.1 Tỷ lệ review 1-2 sao và quy mô quan sát theo nền tảng v
Hình MC.2 Tỷ lệ đề cập khía cạnh trong nhóm review sao thấp vi
Hình MC.3 Màn hình Tổng quan với bộ lọc chỉ số và biểu đồ xu hướng ix
Hình 3.1: Kiến trúc các thành phần của hệ thống 12
Hình 3.2: Luồng đọc chuẩn hóa khử trùng và tổng hợp batch 15
Hình 3.3: Luồng Kafka replay checkpoint và chống trùng 18
Hình 5.1: Tỷ lệ sao thấp của bốn nền tảng trong snapshot 28
Hình 5.2: Tỷ lệ sao thấp và lượng review theo năm 29
Hình 5.3: Ma trận tỷ lệ đề cập khía cạnh theo nền tảng 30
Hình 5.4: Màn hình Tổng quan của sản phẩm ReviewLens 33

DANH MỤC BẢNG

Bảng MC.1 Chỉ dẫn kiểm chứng trực tiếp trong tài liệu i
Bảng MC.2 Bốn dòng kết quả thực tế trong platform_summary.csv iv
Bảng MC.3 Offset và số ID mới trong hai lượt phát ban đầu vii
Bảng MC.4 Trạng thái chín task của run validation_20261012 viii
Bảng MC.5 Nhật ký lỗi và cách khắc phục có nguồn đối chiếu x
Bảng 2.1: Hồ sơ kiểm tra dữ liệu gốc 6
Bảng 2.2: Các trường trong CSV và vai trò trong phân tích 7
Bảng 2.3: Ánh xạ appid sang nền tảng và quy mô raw 8
Bảng 2.4: Yêu cầu và tiêu chí kiểm chứng của hệ thống 9
Bảng 2.5: Ánh xạ chín bước thực hành sang đồ án phản hồi 10
Bảng 3.1: Các vùng dữ liệu và trách nhiệm lưu trữ 12
Bảng 3.2: Các trường của dữ liệu processed 13
Bảng 3.3: Bộ khía cạnh và các mẫu từ khóa minh họa 16
Bảng 3.4: Cấu hình thí nghiệm K-Means 17
Bảng 4.1: Môi trường triển khai và các phiên bản sử dụng 20
Bảng 4.2: Kết quả kiểm tra block của file raw trên HDFS 21
Bảng 4.3: Đối soát số dòng sau làm sạch 22
Bảng 4.4: Số review duy nhất mới trong hai lượt replay 24
Bảng 4.5: Trạng thái chín task trong lần kiểm chứng Airflow 25
Bảng 4.6: Nhóm kiểm tra tự động và kết quả 26
Bảng 4.7: Thời gian nội bộ từng stage trong lần batch đầu 27
Bảng 5.1: Thống kê review sau làm sạch theo nền tảng 28
Bảng 5.2: Số review sao thấp đề cập từng khía cạnh trên toàn tập 30
Bảng 5.3: Tỷ lệ có đề cập khía cạnh và phần chưa gán 31
Bảng 5.4: Từ khóa nổi bật của tám cụm khám phá 31

MỞ ĐẦU

1. GIỚI THIỆU ĐỀ TÀI

Phản hồi trên các ứng dụng thương mại điện tử phản ánh trải nghiệm đặt hàng, vận chuyển, thanh toán và sử dụng ứng dụng. Nhóm lựa chọn đề tài này để tổ chức quy trình lưu trữ, xử lý và khai thác phản hồi theo nội dung môn học Bigdata, giúp quan sát xu hướng theo nền tảng và thời gian.

Qua khảo sát bộ dữ liệu Vietnamese E-commerce Review trên Kaggle [1], nhóm xác định nguồn thực tế là các đánh giá ứng dụng Google Play của Shopee, Lazada, Sendo và Tiki. Vì vậy, đơn vị quan sát trong báo cáo là một review ứng dụng, không phải một đơn hàng hoặc một khách hàng đã xác minh. Tên đề tài thể hiện mục tiêu tìm những vấn đề cần quan tâm; kết quả thực nghiệm được diễn giải là khía cạnh được nhắc trong phản hồi sao thấp, chưa đủ chứng minh khía cạnh đó gây ra sự không hài lòng.

Nhóm triển khai luồng HDFS, Spark, Parquet, Spark SQL, Kafka và Airflow; sau đó xây dựng ReviewLens để quan sát kết quả và đối chiếu văn bản gốc. Trọng tâm đồ án là hiểu cách lưu trữ, phân chia và xử lý dữ liệu, kiểm chứng số liệu và chạy lại quy trình.

2. MỤC TIÊU ĐỀ TÀI

Mục tiêu kỹ thuật là xây dựng pipeline chạy tại máy với HDFS và hai Spark worker, đọc đầy đủ CSV theo schema rõ ràng, tách dữ liệu không hợp lệ vào vùng cách ly, khử trùng khóa review và lưu kết quả phân tích có thể truy vết. Nhóm đặt yêu cầu đối soát số dòng giữa dữ liệu gốc, dữ liệu bị cách ly, bản sao bị loại và dữ liệu được giữ, thay vì chỉ kiểm tra một vài dòng ví dụ.

Mục tiêu phân tích là mô tả lượng phản hồi, phân bố sao và tỷ lệ đánh giá 1-2 sao theo nền tảng và giai đoạn; xác định những khía cạnh được đề cập trong nhóm sao thấp; công khai phần chưa gán được khía cạnh. K-Means được sử dụng trong Spark MLlib để khám phá các nhóm nội dung bổ sung, với tham số và giới hạn diễn giải được ghi rõ.

Mục tiêu vận hành là chứng minh producer, Kafka, Structured Streaming và checkpoint hoạt động trên một luồng phát lại dữ liệu lịch sử; điều phối các bước bằng một DAG có phụ thuộc, retry và log. Mục tiêu sản phẩm là cung cấp biểu đồ,

bộ lọc và tra cứu phản hồi trên toàn bộ tập đã làm sạch để hỗ trợ rà soát vấn đề, đồng thời giữ được mối liên hệ giữa giao diện và kết quả xử lý Bigdata.

3. ĐỐI TƯỢNG VÀ PHẠM VI

Đối tượng nghiên cứu là văn bản phản hồi và mức sao của người dùng các ứng dụng Shopee, Lazada, Sendo và Tiki trong bộ dữ liệu tiếng Việt. Phạm vi dữ liệu theo đề tài là từ năm 2013 đến hết tháng 08/2022. Kiểm tra thực tế ghi nhận thời gian nhỏ nhất là 10/06/2013 01:04:59 và lớn nhất là 27/08/2022 10:44:03. Dữ liệu không có trường vị trí xác minh nơi cư trú của từng người viết, do đó phạm vi Việt Nam được hiểu theo bộ dữ liệu và các ứng dụng được nghiên cứu, không phải một mẫu điều tra đại diện dân số.

Hệ thống được triển khai bằng Docker Compose trên một máy Windows. Hai worker là hai container dùng chung tài nguyên máy chủ vật lý; HDFS có một DataNode với hệ số nhân bản bằng 1. Cấu hình này phục vụ thực hành kiến trúc và quan sát cơ chế xử lý, chưa đại diện cho một cụm sản xuất nhiều máy có khả năng chịu lỗi cao.

Phần thực nghiệm chính sử dụng minh chứng ngày 12/10/2026; phụ lục bổ sung đối soát ngày 15/10 và hồ sơ nộp bài tổng hợp ngày 28/10/2026. Nhóm không thu thập review mới, không xây RFM từ giao dịch và chưa có nhãn người đọc để đánh giá chính xác khía cạnh. Source và hướng dẫn chạy: https://github.com/sangpm2005/DA_BIGDATA.

4. PHƯƠNG PHÁP VÀ BỐ CỤC BÁO CÁO

Nhóm kết hợp khảo sát toàn bộ nguồn CSV, thiết kế hợp đồng dữ liệu, triển khai các thao tác phân tán và đối soát kết quả độc lập. Dữ liệu được phân tích bằng số đếm và tỷ lệ có mẫu số rõ ràng; phản hồi gốc được dùng để kiểm tra cách diễn giải. Khả năng phục hồi được quan sát thông qua chạy lại batch, phát lại cùng sự kiện và sử dụng checkpoint.

Báo cáo gồm năm chương. Chương 1 trình bày bài toán và cơ sở Bigdata. Chương 2 phân tích dữ liệu, yêu cầu và lựa chọn giải pháp. Chương 3 mô tả kiến trúc và các hợp đồng giữa các lớp. Chương 4 trình bày triển khai theo chín bước cùng kiểm chứng kỹ thuật. Chương 5 phân tích kết quả, sản phẩm và tình huống sử dụng. Phần kết luận tổng hợp kết quả đạt được, hạn chế và hướng phát triển.

CHƯƠNG 1 KHẢO SÁT BÀI TOÁN BIGDATA

1.1. BÀI TOÁN KHAI THÁC PHẢN HỒI

Một mức sao cho biết đánh giá tổng thể nhưng không mô tả đầy đủ tình huống người dùng gặp phải. Chẳng hạn, phản hồi về hàng hóa tốt nhưng giao hàng chậm có thể đề cập cả sản phẩm và vận chuyển. Nếu hệ thống gán toàn bộ nội dung thành một nguyên nhân duy nhất, thông tin có thể bị diễn giải sai. Nhóm lựa chọn cách tổng hợp theo thời gian và nền tảng, sau đó cho phép mở phản hồi để kiểm tra ngữ cảnh.

Các câu hỏi phân tích chính gồm: lượng phản hồi và tỷ lệ sao thấp thay đổi như thế nào; khía cạnh nào được nhắc thường xuyên trong review 1-2 sao; có khác biệt giữa các nền tảng và giai đoạn hay không; những review chưa gán khía cạnh chứa nội dung gì; và cùng một logic xử lý có giữ được tính nhất quán khi chạy batch hoặc phát lại qua Kafka hay không. Những câu hỏi này quyết định trường dữ liệu cần giữ và các bảng tổng hợp cần tạo.

Kết quả hỗ trợ bộ phận trải nghiệm ứng dụng, CSKH hoặc vận chuyển khoanh vùng vấn đề để đọc chi tiết. Kết luận lỗi vận hành vẫn cần dữ liệu đơn hàng, log ứng dụng và kiểm tra thực tế; biểu đồ sao thấp chưa đủ để xếp hạng chất lượng dịch vụ.

1.2. CÁCH HIỂU BIGDATA TRONG ĐỒ ÁN

Tập nguồn có 1.300.086 record và dung lượng khoảng 613,18 MiB. Quy mô này vẫn có thể xử lý trên một máy có đủ bộ nhớ, vì vậy việc gọi đồ án là Bigdata không chỉ dựa vào kích thước file. Giá trị môn học nằm ở việc tổ chức lưu trữ theo block, xử lý dữ liệu theo partition trên executor, tổng hợp phân tán, quản lý tiến độ sự kiện và điều phối quy trình có trạng thái.

Nhóm đối chiếu các đặc trưng dữ liệu với yêu cầu hệ thống. Volume thể hiện ở lượng văn bản và nhu cầu giữ lịch sử; variety thể hiện ở văn bản tự do, sao, thời gian và mã ứng dụng; veracity thể hiện ở dữ liệu rỗng, trùng và khác biệt giữa số sao với nội dung. Velocity được thực hành qua luồng replay, không được mô tả thành tốc độ thu thập dữ liệu mới ngoài thực tế. Value là khả năng chuyển dữ liệu đã kiểm chứng thành đầu mối kiểm tra trải nghiệm.

Tăng worker hỗ trợ các bước đã chia partition nhưng chưa giải quyết nút thắt đọc đúng record của một file CSV nhiều dòng. Quá nhiều partition cũng gây file

nhỏ và chi phí điều phối. Nhóm đánh giá khả năng mở rộng theo từng lớp và cấu hình thực nghiệm.

1.3. LƯU TRỮ BẰNG HDFS

HDFS tổ chức file thành các block. NameNode quản lý namespace và thông tin vị trí block; DataNode lưu dữ liệu và phục vụ việc đọc, ghi. Việc nhân bản block giúp bảo vệ dữ liệu khi có nhiều node phù hợp, nhưng cấu hình replication bằng 1 trong đồ án không tạo ra bản sao chịu mất DataNode [2].

Nhóm chia HDFS thành các vùng raw, processed, quarantine, output, models và checkpoints để giữ nguồn và truy vết biến đổi. Kiểm tra block của file thật xác nhận việc lưu trữ, thay vì chỉ dựa vào tên thư mục.

1.4. CƠ CHẾ XỬ LÝ CỦA SPARK

1.4.1. Driver worker và executor

Trong một ứng dụng Spark, driver chạy chương trình và điều phối thực thi; cluster manager cấp tài nguyên; worker là nơi có thể chạy executor; executor thực hiện task và giữ dữ liệu của ứng dụng. Spark master trong chế độ standalone quản lý tài nguyên, không trực tiếp xử lý mọi văn bản review [3].

Trong cấu hình triển khai, hai worker được cấp mỗi worker 2 core; job giới hạn tổng 4 core và 2 core mỗi executor. Các thao tác như kiểm tra cột, gắn khía cạnh và tổng hợp được thực hiện trên dữ liệu phân chia. Driver chỉ nhận các bảng tổng hợp nhỏ hoặc metadata có giới hạn, không nhận toàn bộ văn bản bằng collect.

1.4.2. Transformation action và shuffle

Transformation như select, filter và withColumn mô tả kế hoạch; action như count hoặc ghi file kích hoạt xử lý. Shuffle là trao đổi dữ liệu khi cần tập hợp cùng khóa về cùng nhóm, ví dụ repartition, khử trùng hoặc GROUP BY. Persist cho phép tái sử dụng dữ liệu giữa các action, nhưng cũng tiêu thụ tài nguyên [4].

Nhóm dùng MEMORY_AND_DISK cho dữ liệu được đếm, kiểm tra và ghi nhiều lần, sau đó unpersist. Vị trí shuffle được xác định từ code và kế hoạch thực thi. Chi phí parse nguồn, trao đổi dữ liệu và ghi đĩa được xem xét cùng chi phí xử lý nội dung.

1.4.3. Parquet và truy vấn theo partition

Parquet lưu dữ liệu theo cột và giữ schema. Spark có thể tận dụng partition của đường dẫn và lựa chọn cột cần đọc để giảm lượng dữ liệu được truy vấn [5]. Trong đồ án, processed được tổ chức theo platform và year, còn month là cột phục vụ thống kê và lọc.

Nhóm lựa chọn platform/year vì dữ liệu có bốn nền tảng và gần mười năm lịch sử. Chia ngay theo từng tháng có thể tạo nhiều file nhỏ. Đây là lựa chọn cho quy mô hiện tại; khi dữ liệu tăng, cần đo kích thước file và thời gian truy vấn trước khi xác định lại chiến lược partition.

1.5. KAFKA STRUCTURED STREAMING VÀ AIRFLOW

Kafka lưu các sự kiện trong topic được chia partition. Producer gửi sự kiện; consumer đọc theo vị trí offset của từng partition. Việc giữ log cho phép đọc lại sự kiện [6]. Trong đồ án, topic nhận các review lịch sử được phát lại để thực hành đường đi của dữ liệu qua hệ thống.

Structured Streaming thực hiện xử lý tăng dần và sử dụng checkpoint để giữ tiến độ cùng trạng thái cần khôi phục [7]. Nhóm sử dụng microbatch, gắn khóa ổn định và thử replay cùng tập dữ liệu để quan sát chống trùng. Hệ thống phân biệt thời gian review với thời gian ingest, vì phản hồi năm 2013 không trở thành phản hồi mới năm 2026 chỉ do được phát lại.

Airflow biểu diễn công việc dưới dạng DAG với các task và phụ thuộc, đồng thời quản lý retry và log [8]. Nhóm dùng Airflow để điều phối các job, còn phần xử lý vẫn chạy bằng Spark. Do nguồn là một snapshot lịch sử cố định, DAG sử dụng schedule=None; khi cần thực nghiệm, nhóm chủ động trigger thay vì tạo lịch giả định có dữ liệu mới hằng ngày.

1.6. VAI TRÒ CỦA PHÂN TÍCH NỘI DUNG

Nhóm dùng luật từ khóa để nhận diện đề cập và TF-IDF/K-Means để khám phá nội dung. K-Means là phân cụm không giám sát trên vector, cần chọn trước số cụm; Spark MLlib cung cấp bộ ước lượng tương ứng [9]. Silhouette phản ánh phân tách cụm, không phải độ chính xác khía cạnh. Phân tích nội dung được thực hiện sau thống kê cơ bản, cùng hợp đồng dữ liệu và đối soát của pipeline.

CHƯƠNG 2 PHÂN TÍCH DỮ LIỆU VÀ YÊU CẦU

2.1. KHẢO SÁT NGUỒN DỮ LIỆU

Nhóm sử dụng file vietnamese_ecommerce_review.csv đã tải từ Kaggle. Trước khi đưa vào hệ thống phân tán, nhóm đọc toàn bộ record bằng bộ đọc CSV có hỗ trợ dấu nháy và xuống dòng trong trường. Số dòng vật lý không được dùng thay cho số review vì một nội dung có thể chứa nhiều dòng.

Bảng 2.1: Hồ sơ kiểm tra dữ liệu gốc

Chỉ số	Kết quả
Dung lượng	642.967.981 byte (613,18 MiB)
Số record CSV	1.300.086
Thời gian nhỏ nhất	10/06/2013 01:04:59
Thời gian lớn nhất	27/08/2022 10:44:03
Record ngoài phạm vi	0
Nội dung rỗng ở raw	71
Sao không hợp lệ	2 (score bằng 0)
Thời gian không parse được	0
Sai số trường CSV	0
Bản sao khóa appid/reviewid	139
Lặp nội dung trong cùng ứng dụng	638.855 theo audit ban đầu
Ứng viên spam theo luật ban đầu	88

Bảng 2.1 cho thấy nguồn không có record ngoài phạm vi thời gian hoặc lỗi thời gian không parse được, nhưng có nội dung rỗng, sao bằng 0 và bản sao khóa review. Nhóm giữ fingerprint SHA-256 để nhận biết cùng một nguồn qua các lần upload và chạy lại. Fingerprint là thông tin xác minh file nguồn; không thay thế metadata block hoặc checksum nội bộ của HDFS.

2.1.1. Các trường dữ liệu

Bảng 2.2: Các trường trong CSV và vai trò trong phân tích

Trường	Kiểu raw	Ý nghĩa	Cách sử dụng
csv_index	Chuỗi	Index khi xuất CSV	Không dùng làm khóa review
reviewid	Chuỗi	Mã review	Khóa dedup kết hợp appid
username	Chuỗi	Tên hiển thị	Bỏ khỏi tập phân tích
userimage	Chuỗi	URL ảnh người viết	Bỏ khỏi tập phân tích
content	Chuỗi	Văn bản phản hồi	Giữ bản gốc và chuẩn hóa
score	Chuỗi	Số sao đánh giá	Cast int và kiểm tra 1-5
thumbsupcount	Chuỗi	Lượt thấy hữu ích	Không dùng thay tiền giao dịch
reviewcreatedversion	Chuỗi	Phiên bản ứng dụng	Chưa dùng trong phân tích chính
at	Chuỗi	Thời gian review	Parse timestamp và tạo year/month
replycontent	Chuỗi	Nội dung nhà phát triển trả lời	Không ghép vào review
repliedat	Chuỗi	Thời gian trả lời	Chưa dùng trong phân tích chính
appid	Chuỗi	Mã ứng dụng	Ánh xạ nền tảng

Các trường reviewid, appid, content, score và at là đầu vào chính. Nhóm không dùng username như một mã khách hàng ổn định và không chuyển thumbsupcount thành giá trị tiền mua hàng. Trường phản hồi của nhà phát triển có thể hữu ích cho nghiên cứu khác, nhưng không được ghép vào nội dung đánh giá để tránh lẫn tiếng nói người dùng với câu trả lời của đơn vị cung cấp ứng dụng.

2.1.2. Ánh xạ nền tảng và đơn vị quan sát

Bảng 2.3: Ánh xạ appid sang nền tảng và quy mô raw

Nền tảng	App ID	Review raw
Shopee	com.shopee.vn	519.297
Lazada	com.lazada.android	530.491
Sendo	com.sendo	179.643
Tiki	vn.tiki.app.tikiandroid	70.655

Khóa khử trùng được xác định từ appid và reviewid. Sau xử lý, review_key là khóa băm dùng để truy vết, không phải mã khách hàng. Một người có thể có nhiều review và dữ liệu không chứa lịch sử đơn hàng đã xác minh; do đó nhóm phân tích theo review, nền tảng và thời gian thay vì suy ra hồ sơ mua sắm của từng người.

2.2. PHÂN TÍCH CHẤT LƯỢNG VÀ QUY TẮC XỬ LÝ

2.2.1. Dữ liệu không hợp lệ và vùng cách ly

Nhóm kiểm tra schema CSV, reviewid, nội dung sau chuẩn hóa, sao trong khoảng 1 đến 5, thời gian và nền tảng. Record không đạt điều kiện được ghi vào quarantine cùng lý do, giúp kiểm tra lại nguồn và giải thích thay đổi số lượng. Các điều kiện này là kiểm tra cấu trúc, không khẳng định nội dung đạt chất lượng ngữ nghĩa.

Ở raw có 71 nội dung rỗng. Sau chuẩn hóa Unicode, một review chỉ chứa ký tự vô hình U+200D cũng trở thành rỗng, nên tổng thiếu nội dung là 72. Kết hợp hai record sao bằng 0, quarantine có 74 record. Chênh lệch này được giải thích từ phép biến đổi, không được gộp chung thành lỗi mất dữ liệu của Spark.

2.2.2. Khử trùng ID và nội dung lặp

Có 139 bản sao khóa appid/reviewid. Nhóm chọn bản có thời gian mới nhất và sử dụng khóa nội dung để phân xử ổn định khi thời gian bằng nhau. Quy tắc này phục vụ tính nhất quán khi chạy lại, tránh chọn bản còn lại theo thứ tự đọc không bảo đảm.

Audit ghi nhận 638.855 lần lặp nội dung chuẩn hóa trong cùng ứng dụng theo quy tắc kiểm tra ban đầu. Nhóm không xóa hàng loạt những review khác ID có

cùng nội dung, vì các từ ngắn như “ok” hoặc “tốt” có thể được nhiều người sử dụng. Xóa chúng sẽ làm thay đổi phân bố sao và tỷ lệ theo một giả định chưa được chứng minh.

2.2.3. Chuẩn hóa văn bản và cờ ứng viên spam

Nhóm chuẩn hóa Unicode, chữ thường và khoảng trắng; loại ký tự vô hình không mang nội dung. Các từ phủ định như “không”, “chưa”, “chẳng” và dấu tiếng Việt được giữ trong dữ liệu phân tích. Nếu xóa phủ định hoặc bỏ dấu ở bước phân tích, ý nghĩa phản hồi có thể thay đổi và làm giảm tính hợp lý của luật khía cạnh.

Cờ spam_candidate nhận diện một số mẫu quảng cáo, vay tiền và liên kết. Audit ban đầu có 88 ứng viên; cờ này không chứng minh dữ liệu chỉ có 88 spam. Bản thống kê chính giữ những review đã đạt kiểm tra cấu trúc, còn dashboard cho phép loại ứng viên để phân tích độ nhạy. Tên và avatar người viết được bỏ khỏi tập phân tích và chỉ mục tra cứu.

2.3. YÊU CẦU CHỨC NĂNG VÀ TIÊU CHÍ KIỂM CHỨNG

Nhóm chuyển mục tiêu môn học thành các yêu cầu có thể quan sát và kiểm tra. Một bước được xem là hoàn thành khi có dữ liệu lưu thật hoặc bằng chứng thực thi, không chỉ khi câu lệnh chạy không báo lỗi.

Bảng 2.4: Yêu cầu và tiêu chí kiểm chứng của hệ thống

Yêu cầu	Bằng chứng kiểm chứng
Giữ và truy vết nguồn	File raw HDFS, số byte và SHA-256
Đọc đúng toàn bộ review	Count Spark khớp audit CSV
Làm sạch có giải thích	Quarantine có reason và phương trình số dòng
Khử trùng hợp lý	Khóa review duy nhất; giữ ID khác cùng nội dung
Thống kê theo phạm vi	Số đếm và tỷ lệ dùng cùng sàn/tháng
Xử lý phân tán	Hai worker, task/stage và kế hoạch có Exchange
Khôi phục streaming	Offset tăng; unique không tăng khi replay
Điều phối và chạy lại	DAG, retry, log và số đếm batch không đổi

Yêu cầu	Bằng chứng kiểm chứng
Sản phẩm có nguồn gốc số liệu	Cube/chỉ mục cùng generation và đối soát toàn bộ

Việc hiển thị biểu đồ cần đi kèm định nghĩa chỉ số, nguồn và phạm vi. Khi thay đổi sàn hoặc tháng, mẫu số cũng phải thay đổi tương ứng. Việc tìm kiếm cần áp dụng trên toàn bộ processed, có phân trang và có thể truy vết bằng khóa review; một tập ví dụ chọn trước không đáp ứng yêu cầu tra cứu toàn bộ dữ liệu.

2.4. ĐIỀU CHỈNH LUỒNG THỰC HÀNH THEO ĐỀ TÀI

Luồng thực hành gồm chuẩn bị HDFS, upload, đọc bằng Spark, làm sạch, Spark SQL, RFM/K-Means, lưu kết quả, Kafka ingest và Airflow. Nhóm giữ các thành phần Bigdata và điều chỉnh nội dung nghiệp vụ ở những bước không phù hợp với dữ liệu review.

Bảng 2.5: Ánh xạ chín bước thực hành sang đồ án phản hồi

Bước	Nội dung thực hiện	Đầu ra
1	Chuẩn bị HDFS	Các vùng raw, processed, output, quarantine
2	Upload CSV	Raw và fingerprint
3	Đọc bằng Spark	Schema và count đầy đủ
4	Làm sạch	Parquet theo platform/year và dữ liệu lỗi
5	Spark SQL	Thống kê sàn, tháng, sao, khía cạnh
6	Thống kê review và K-Means thay RFM	Đề cập, cụm khám phá và metadata
7	Lưu kết quả và lớp phục vụ	HDFS output, cube và chỉ mục
8	Kafka ingest bằng replay	Parquet streaming, checkpoint, metric
9	Airflow và kiểm chứng hoàn thành	DAG success và đối soát

RFM cần dữ liệu Recency, Frequency và Monetary có ý nghĩa ở cấp giao dịch hoặc khách hàng. Bộ dữ liệu không có giá trị đơn hàng và định danh khách hàng đáng tin cậy, nên tạo Monetary từ lượt hữu ích sẽ làm sai bản chất chỉ số. Nhóm thay nội dung RFM bằng thống kê phản hồi và đề cập khía cạnh, đồng thời giữ K-Means để khám phá nội dung trong Spark MLlib. Bước tính Amount trong bài toán giao dịch cũng được thay bằng kiểm tra sao, thời gian, văn bản và Parquet.

2.5. ĐỊNH NGHĨA CHỈ SỐ VÀ GIẢ THUYẾT PHÂN TÍCH

Với nền tảng p và giai đoạn t, nhóm ký hiệu N là số review sau làm sạch, L là số review có score thuộc {1, 2}, và A(a) là số review trong L đề cập khía cạnh a. Tỷ lệ sao thấp R được tính bằng L/N. Tỷ lệ đề cập khía cạnh M(a) được tính bằng A(a)/L. Nếu mẫu số bằng 0, chỉ số được trình bày là chưa có dữ liệu thay vì gán giá trị 0%.

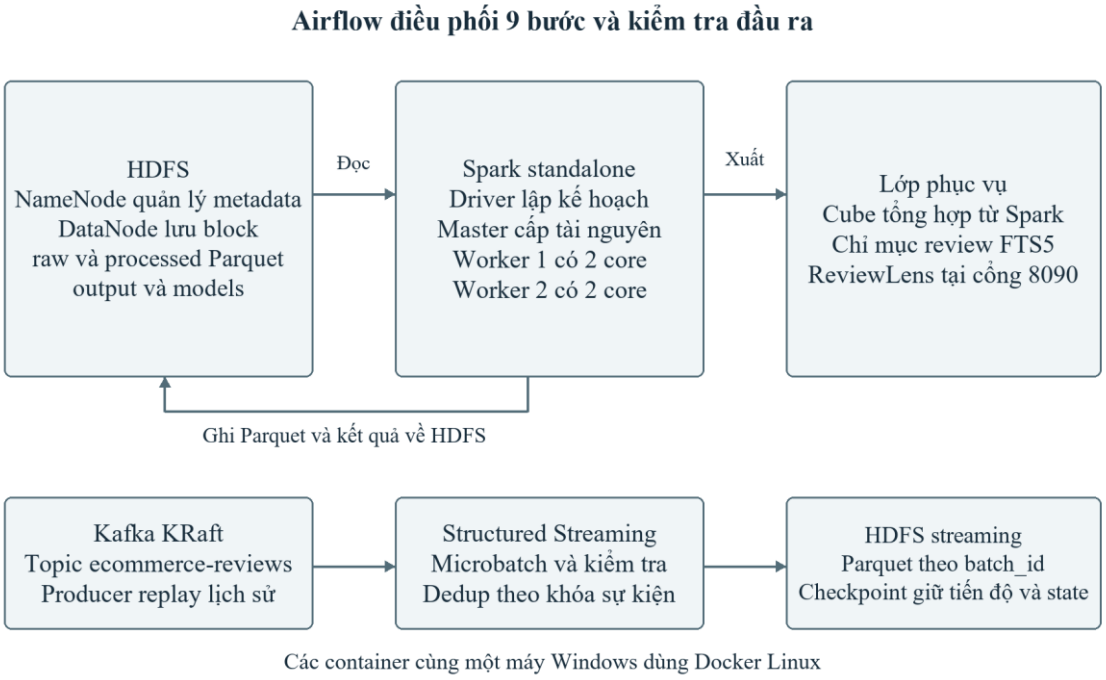
Điểm trung bình được tính bằng tổng score chia cho N, hoặc từ tổng có trọng số của số review ở từng mức sao. Khi gộp tháng hoặc nền tảng, nhóm cộng số đếm trước rồi tính lại tỷ lệ; không lấy trung bình đơn giản của các tỷ lệ nhóm có quy mô khác nhau. Một review có thể mang nhiều nhãn đề cập, nên tổng tỷ lệ khía cạnh có thể vượt 100%.

Nhóm sử dụng sao thấp như tín hiệu thay thế cho không hài lòng, không phải nhãn cảm xúc chuẩn. Giả thuyết làm việc là những khía cạnh được nhắc nhiều trong nhóm này có thể tạo đầu mối ưu tiên rà soát. Giả thuyết chỉ được củng cố khi đọc ngữ cảnh; ví dụ “hàng tốt nhưng giao chậm” cho thấy không thể coi cả sản phẩm và vận chuyển đều bị chê chỉ vì cùng xuất hiện trong một review sao thấp.

CHƯƠNG 3 THIẾT KẾ PIPELINE BIGDATA

3.1. KIẾN TRÚC TỔNG THỂ

Nhóm thiết kế ba lớp xử lý chính: lưu trữ nguồn và kết quả trên HDFS; xử lý batch/streaming bằng Spark; phục vụ quan sát qua bảng tổng hợp và chỉ mục. Airflow điều phối đường đi giữa các bước. Docker Compose xác định dịch vụ, mạng nội bộ, volume và giới hạn tài nguyên để môi trường có thể dựng lại.



Hình 3.1: Kiến trúc các thành phần của hệ thống

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Trong Hình 3.1, đường batch bắt đầu từ CSV raw và đi qua processed Parquet đến thống kê. Đường replay bắt đầu từ mẫu lịch sử, đi qua Kafka và Structured Streaming đến HDFS cùng checkpoint. Lớp phục vụ được xây từ processed, không đọc CSV gốc mỗi lần người dùng bấm biểu đồ. Hai worker và một DataNode trong sơ đồ đều chạy trên cùng một máy vật lý.

3.2. TỔ CHỨC CÁC VÙNG DỮ LIỆU TRÊN HDFS

Bảng 3.1: Các vùng dữ liệu và trách nhiệm lưu trữ

Đường dẫn dưới /ecommerce	Nội dung và trách nhiệm
raw/reviews.csv	Nguồn CSV giữ nguyên, xác minh bằng fingerprint

Đường dẫn dưới /ecommerce	Nội dung và trách nhiệm
processed/reviews	Review hợp lệ sau dedup, Parquet theo sàn/năm
quarantine	Dữ liệu không hợp lệ cùng lý do
output	Bảng tổng hợp và metadata phân tích
models	Feature pipeline và mô hình K-Means
streaming	Parquet review và metric theo batch_id
checkpoints/reviews-v1	Tiến độ Kafka và state chống trùng
serving/review_index	JSON gzip phân tán xuất từ processed

Raw được xem là nguồn giữ nguyên. Khi file ở cùng đường dẫn đã tồn tại, bước upload kiểm tra SHA-256; cùng nguồn thì bỏ qua upload, nguồn khác thì từ chối ghi đè để yêu cầu đường dẫn raw mới. Processed và output có thể được tạo lại từ cùng raw, còn checkpoint phải được giữ để quan sát tiến độ streaming và trạng thái chống trùng.

Nhóm dùng Parquet cho processed và kết quả cần đọc bằng Spark. CSV trong thư mục outputs trên máy là bảng tổng hợp nhỏ phục vụ báo cáo hoặc giao diện, không phải nơi thay thế toàn bộ kho HDFS. Việc giữ các loại dữ liệu ở vùng riêng giúp xác định nguyên nhân khi số lượng đầu ra không đúng.

3.3. THIẾT KẾ HỢP ĐỒNG DỮ LIỆU

3.3.1. Hợp đồng processed

Bảng 3.2: Các trường của dữ liệu processed

Trường	Kiểu	Vai trò
review_key	String	Khóa băm để truy vết, không phải customer ID
platform	String	Shopee, Lazada, Sendo, Tiki
content	String	Văn bản gốc
normalized_content	String	Văn bản sau chuẩn hóa để áp dụng luật
score	Integer	Sao hợp lệ 1-5

Trường	Kiểu	Vai trò
at	Timestamp	Thời gian review
year	Integer	Partition theo năm
month	String	Tháng dạng yyyy-MM
low_rating_proxy	Boolean	Sao thuộc 1-2
spam_candidate	Boolean	Ứng viên cần kiểm tra theo luật
aspects_mentioned	Array of String	Danh sách đề cập, cho phép rỗng/đa nhãn

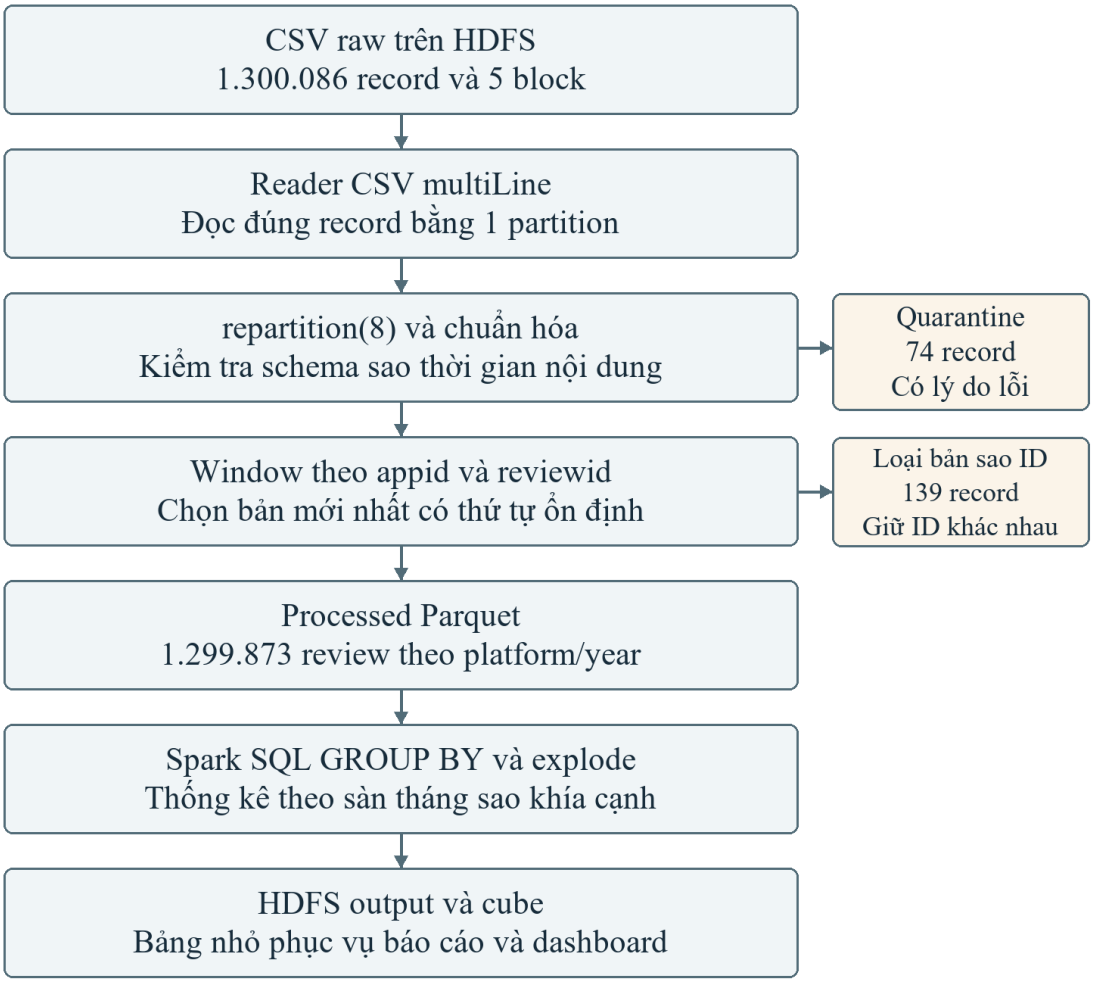
Processed chứa văn bản gốc để kiểm tra ngữ cảnh và văn bản chuẩn hóa để áp dụng luật. Danh sách aspects_mentioned có thể rỗng hoặc có nhiều phần tử; hệ thống không ép mọi review vào một nhóm. Quarantine giữ khóa, các trường liên quan và validation_reasons để truy vết lỗi. Username và userimage không được chuyển sang processed.

3.3.2. Hợp đồng sự kiện và thời gian

Sự kiện Kafka gồm event_id ổn định, appid, content, score, event_time, ingested_at và source_mode. event_time giữ thời điểm review ban đầu; ingested_at là thời điểm phát lại hiện tại; source_mode ghi rõ historical_replay. Consumer còn có topic, partition và offset để theo dõi vị trí sự kiện.

Nhóm giữ event_id làm khóa chống trùng trong replay. Nếu không có khóa ổn định, consumer chỉ có thể phân biệt vị trí trong log, còn cùng nội dung phát lại ở một offset mới vẫn có thể bị tính thành review mới. Không dùng thời gian hiện tại để loại review lịch sử theo watermark trong demo này, vì điều đó làm mất dữ liệu theo một giả định thời gian không phù hợp.

3.4. THIẾT KẾ XỬ LÝ BATCH VÀ SPARK SQL



Hình 3.2: Luồng đọc chuẩn hóa khử trùng và tổng hợp batch

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Nhóm đọc CSV với multiLine=true, quote và escape phù hợp, sau đó repartition(8) để phân phối dữ liệu cho các phép xử lý tiếp theo. Khử trùng theo cửa sổ appid/reviewid cần tập hợp cùng khóa và sắp xếp có thứ tự. Khi ghi processed, nhóm repartition theo platform/year rồi partitionBy các cột này. Số 8 là cấu hình thực hành, không được xem là mức tối ưu cho mọi dữ liệu.

Các bảng Spark SQL gồm thống kê theo sàn, theo tháng, phân bố sao, đề cập khía cạnh, chưa gán khía cạnh và độ nhạy với cờ spam. Đối với khía cạnh đa nhãn, thao tác explode tạo nhiều dòng cho một review trong bảng đề cập; mẫu số vẫn được lấy từ bảng tổng review sao thấp cùng phạm vi. Cách tổ chức này tránh lấy tổng dòng sau explode làm số review.

Nhóm lưu kế hoạch explain của truy vấn lọc Shopee năm 2022 và GROUP BY theo tháng. PartitionFilters cho biết các partition được lọc; ReadSchema cho biết cột dữ liệu cần đọc; Exchange thể hiện shuffle. Vì các tên sàn/năm có thể được lấy từ đường dẫn partition, phần schema cột đọc bên trong file có thể nhỏ hơn tập cột được dùng trong truy vấn.

3.5. THIẾT KẾ NHẬN DIỆN ĐỀ CẬP VÀ PHÂN CỤM

3.5.1. Bộ khía cạnh và phương pháp theo luật

Bảng 3.3: Bộ khía cạnh và các mẫu từ khóa minh họa

Khía cạnh	Ví dụ mẫu từ khóa
Ứng dụng	ứng dụng, app, đăng nhập, cập nhật, lag, không vào
Vận chuyển	giao hàng, giao chậm, vận chuyển, shipper, phí ship
Sản phẩm	chất lượng, hàng giả, sản phẩm, đóng gói, hàng tốt
Chăm sóc khách hàng	cskh, tổng đài, hỗ trợ, khiếu nại, nhân viên
Thanh toán	thanh toán, trừ tiền, thẻ, ví điện tử, chuyển khoản
Giá và khuyến mãi	giảm giá, voucher, mã giảm, giá cao, sale
Đổi trả và hoàn tiền	hoàn tiền, đổi trả, trả hàng, hủy đơn, refund

Luật được khai báo trong config/aspects.json và áp dụng lên normalized_content. Review có thể khớp nhiều luật. Các mẫu như “hàng tốt” hoặc “giá rẻ” giúp nhận diện việc nhắc đến chủ đề, đồng thời cho thấy bộ luật không phải bộ phân loại cảm xúc tiêu cực. Nhóm giữ khái niệm đề cập để phù hợp với phép xử lý thật.

3.5.2. Vector hóa và K-Means trong Spark

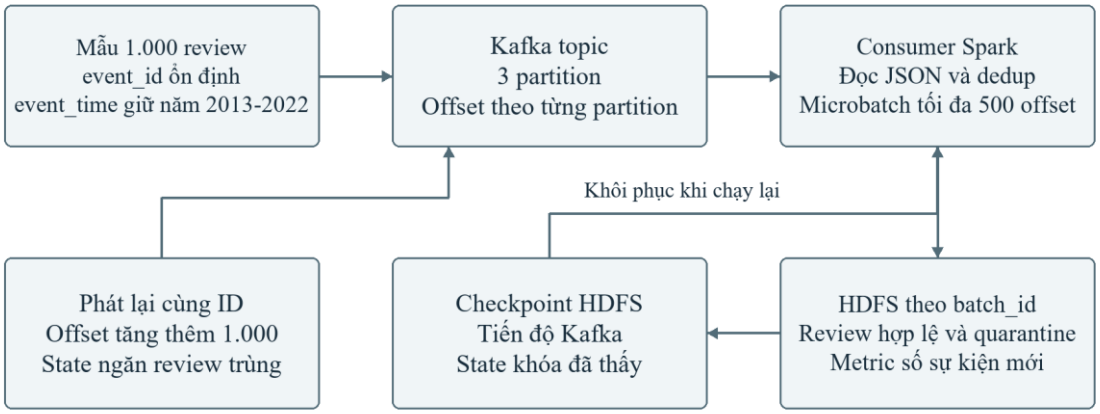
Nhóm chọn review 1-2 sao, không có cờ spam và có văn bản chuẩn hóa dài ít nhất 10 ký tự; lấy mẫu ổn định theo hash review_key ở mức 25%. Văn bản được tách theo âm tiết unigram và bigram, tạo đặc trưng TF-IDF và chuẩn hóa vector. TF-IDF kết hợp tần suất trong văn bản và mức phổ biến trong tập văn bản [10]. Cách tách này chưa phải bộ tách từ tiếng Việt hoàn chỉnh.

Bảng 3.4: Cấu hình thí nghiệm K-Means

Thiết lập	Giá trị
Dữ liệu ứng viên	Review sao thấp, không cờ spam, ít nhất 10 ký tự
Lấy mẫu	Hash review_key ở mức 25%
Vector cuối cùng	61.241 vector khác 0
Token	Âm tiết unigram và bigram; tối thiểu 2 ký tự
CountVectorizer	vocabSize=10.000; minDF=10
Vector hóa	TF-IDF và chuẩn hóa L2
K-Means	K=8; seed=42; maxIter=20
Khoảng cách	Cosine
Silhouette	Mẫu đánh giá tối đa 10.000 dòng

Nhóm lưu feature pipeline, mô hình, gán cụm của mẫu, từ khóa và ví dụ vào HDFS. Những vector bằng 0 được loại trước phân cụm. K-Means chỉ dùng để khám phá, vì không có nhãn chuẩn để chọn số cụm hoặc xác định độ chính xác khía cạnh. Việc giữ mẫu có seed/hash và ghi metadata giúp mô tả đúng điều kiện thí nghiệm.

3.6. THIẾT KẾ STREAMING VÀ ĐIỀU PHỐI



Hình 3.3: Luồng Kafka replay checkpoint và chống trùng

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Consumer đọc JSON từ Kafka, sử dụng dropDuplicates theo dedup_key trước xử lý microbatch và dùng lại logic enrich/validation của batch. Mỗi batch ghi Parquet theo batch_id, ghi dữ liệu lỗi và metadata số sự kiện mới. Hệ thống sử dụng overwrite cho cùng batch_id để hỗ trợ retry cùng batch; không gộp mọi lần phát lại thành các file append không kiểm soát.

Checkpoint tại /ecommerce/checkpoints/reviews-v1 giữ tiến độ và state qua các lần khởi động. State chống trùng không đặt watermark nên có thể tăng theo số ID. Nhóm chấp nhận điều này cho demo hữu hạn 1.000 review; khi phục vụ liên tục cần thiết kế retention hoặc upsert phù hợp, thay vì tuyên bố state không giới hạn dùng được cho sản xuất.

DAG liên kết chín task theo thứ tự phụ thuộc. Task 07 còn tạo cube và chỉ mục để phục vụ dashboard; task 09 đối soát dữ liệu HDFS thật và mọi ô tổng hợp của cube. Retry được giới hạn một lần với khoảng chờ 30 giây, timeout mỗi task 40 phút, max_active_runs bằng 1. Các lựa chọn này tránh chồng nhiều lần chạy lên cùng output của snapshot.

3.7. THIẾT KẾ LỚP PHỤC VỤ REVIEWLENS

Spark tạo cube theo platform, month, score và spam_candidate, kèm số review, số chưa gán và số đề cập từng khía cạnh. Snapshot hiện tại có 1.910 dòng, nằm dưới giới hạn xuất 10.000 dòng của job. Khi người dùng đổi bộ lọc, web cộng các số đếm trong cube rồi tính lại tỷ lệ và điểm trung bình. Đây là cách phục vụ tương tác từ kết quả tổng hợp đã kiểm chứng.

Để tra cứu văn bản, Spark xuất toàn bộ processed thành các phần JSON gzip trên HDFS. Script đọc tuần tự luồng export để xây chỉ mục SQLite FTS5, một cơ chế tìm kiếm toàn văn [11]. SQLite là lớp phục vụ trên laptop, không được mô tả là kho dữ liệu phân tán. Chuẩn hóa không dấu chỉ dùng ở cột tìm kiếm; văn bản hiển thị vẫn được giữ.

Cube, metadata và chỉ mục gắn cùng generation và được kiểm tra tổng số dòng trước khi phục vụ. Chỉ mục mới được thay thế sau khi build và kiểm tra thành công. Docker giữ một bản cache trên volume Linux để giảm chi phí đọc ngẫu nhiên qua ổ Windows, tự làm mới khi generation thay đổi. Nếu snapshot đang cập nhật hoặc chưa đồng bộ, API trả thông báo chưa sẵn sàng để tránh công bố kết quả trộn giữa hai lần chạy.

CHƯƠNG 4 TRIỂN KHAI VÀ KIỂM CHỨNG

4.1. MÔI TRƯỜNG VÀ CẤU TRÚC SOURCE

Bảng 4.1: Môi trường triển khai và các phiên bản sử dụng

Thành phần	Cấu hình triển khai
Máy thực hành	Windows, khoảng 24 GB RAM; Docker Linux khoảng 11,5 GiB
HDFS	Apache Hadoop 3.3.6; 1 NameNode, 1 DataNode
Spark	3.5.7, standalone; 2 worker x 2 core
Runtime xử lý	Java 11, Scala 2.12, Python 3.11
Kafka	Apache Kafka 3.9.0, KRaft, 1 broker, topic 3 partition
Airflow	2.10.5, LocalExecutor
Metadata Airflow	PostgreSQL 16.6
Lớp phục vụ	Python, HTML/CSS/JS; SQLite FTS5
Các cổng tại localhost	9870 HDFS; 8081 Spark; 8080 Airflow; 8090 ReviewLens

Các dịch vụ được khai báo trong compose.yaml. Nhóm tách jobs chứa các chương trình xử lý, src/review_analytics chứa logic dùng lại, config chứa bộ khía cạnh, dags chứa quy trình điều phối, scripts chứa audit/kiểm tra và dashboard chứa lớp phục vụ. CSV gốc cùng các tệp Parquet, chỉ mục và log được loại khỏi source bằng .gitignore.

Môi trường dùng Spark standalone để quan sát driver và executor rõ ràng trong phạm vi máy thực hành. PostgreSQL lưu metadata Airflow, không phải kho chứa toàn bộ review. Các cổng giao diện chỉ công bố tại localhost; trao đổi giữa các dịch vụ sử dụng tên dịch vụ trong mạng Docker.

4.2. CHUẨN BỊ HDFS VÀ UPLOAD NGUỒN

Nhóm khởi động NameNode, DataNode và các dịch vụ Spark trước khi upload. Script bootstrap_hdfs.py tạo các vùng dữ liệu, chờ HDFS sẵn sàng và kiểm tra fingerprint khi raw đã tồn tại. Sau upload, nhóm dùng lệnh hdfs dfs -ls và hdfs fsck để xác nhận file và vị trí block.

```
hdfs dfs -ls /ecommerce/raw
hdfs fsck /ecommerce/raw/reviews.csv -files -blocks -locations
hdfs dfsadmin -report
```

Bảng 4.2: Kết quả kiểm tra block của file raw trên HDFS

Block	Số byte	Replica
0	134.217.728	1
1	134.217.728	1
2	134.217.728	1
3	134.217.728	1
4	106.097.069	1
Tổng	642.967.981	Một DataNode

File 642.967.981 byte được lưu thành năm block: bốn block đầu 134.217.728 byte và block cuối 106.097.069 byte. Kết quả fsck ghi HEALTHY, không có block thiếu hoặc hỏng. Bằng chứng này xác nhận cơ chế lưu block, đồng thời cho thấy mọi block chỉ có một replica trên một DataNode trong cấu hình thực hành.

4.3. ĐỌC CSV VÀ LÀM SẠCH BẰNG SPARK

4.3.1. Đọc đúng ranh giới record

Nhóm dùng schema chuỗi cho các trường raw rồi cast các cột cần phân tích. Cách này giúp tách kiểm tra cấu trúc khỏi chuyển kiểu, tránh suy luận schema khác nhau giữa các lần đọc. Bộ đọc sử dụng chế độ PERMISSIVE và cột _corrupt_record để lưu dấu dữ liệu không đúng định dạng [12].

```
raw = (spark.read.schema(RAW_SCHEMA)
   .option("header", True)
   .option("multiLine", True)
   .option("quote", "").option("escape", "")
   .option("mode", "PERMISSIVE")
   .option("columnNameOfCorruptRecord", "_corrupt_record")
   .csv("hdfs://namenode:9000/ecommerce/raw/reviews.csv"))
```

Spark đọc được 1.300.086 record, khớp audit độc lập. Reader có một partition do file CSV sử dụng trường nhiều dòng. Năm block HDFS không đồng nghĩa file

CSV này được chia thành năm task parse độc lập. Nhóm repartition sau khi đọc để tạo dữ liệu phân chia cho xử lý tiếp; đây là điểm cần giải thích khi quan sát tài nguyên của các worker.

4.3.2. Kiểm tra làm sạch và khử trùng

Nhóm sử dụng các hàm enrich, validation_reasons và deduplicate_valid chung cho quy trình. Enrich chuyển sao và thời gian, ánh xạ nền tảng, tạo khóa, cờ sao thấp và danh sách đề cập. Validation tách dòng lỗi. Dedup dùng row_number theo khóa và thứ tự thời gian cùng khóa nội dung để chọn bản nhất quán.

Bảng 4.3: Đối soát số dòng sau làm sạch

Thành phần	Số record	Diễn giải
Raw	1.300.086	Khớp audit và count Spark
Quarantine	74	72 rỗng sau chuẩn hóa và 2 sao bằng 0
Bản sao ID loại bỏ	139	Dedup appid/reviewid
Processed	1.299.873	1.299.873 khóa review duy nhất

Phép đối soát là 1.300.086 = 74 + 139 + 1.299.873. Dữ liệu retained có 1.299.873 khóa review duy nhất khi được đọc lại từ Parquet HDFS. Nhóm giữ riêng số rỗng trước/sau chuẩn hóa để giải thích tác động của Unicode, đồng thời kiểm tra những review khác ID nhưng cùng nội dung vẫn còn trong thống kê.

4.3.3. Ghi Parquet và tránh thu toàn bộ về driver

Processed được ghi bằng mode overwrite cho cùng snapshot và partitionBy(platform, year). Các DataFrame được tái sử dụng cho nhiều action được persist/unpersist trong vòng đời stage. Các collect trong phần metadata chỉ áp dụng cho số nhóm lý do hoặc bảng tổng hợp nhỏ; job phục vụ dashboard đặt giới hạn 10.000 dòng trước khi xuất cube.

Giới hạn collect không chỉ là quy tắc trình bày source. Nếu driver nhận toàn bộ văn bản, bộ nhớ tại driver trở thành nút thắt và việc có thêm worker không làm bước đó mở rộng tốt hơn. Nhóm giữ dữ liệu chi tiết trong Parquet hoặc export phân tán, chỉ đưa kết quả phục vụ phù hợp về máy.

4.4. THỰC HIỆN SPARK SQL VÀ KIỂM TRA KẾ HOẠCH

```
SELECT platform, COUNT(*) AS reviews, AVG(score) AS mean_rating,
    SUM(CASE WHEN score <= 2 THEN 1 ELSE 0 END) AS low_reviews,
    SUM(CASE WHEN score <= 2 THEN 1 ELSE 0 END) / COUNT(*) AS rate
FROM reviews
GROUP BY platform
```

Truy vấn tổng hợp số review, điểm trung bình, số sao thấp và tỷ lệ theo sàn được tính từ processed. Với truy vấn Shopee năm 2022, kế hoạch đã lưu có PartitionFilters theo platform/year và ReadSchema chỉ cần month trong file. Các cột partition được biết từ đường dẫn; Spark không cần đọc mọi cột văn bản của những sàn và năm khác để đếm review theo tháng.

```
HashAggregate [platform, month]
 Exchange hashpartitioning(platform, month, 8)
  HashAggregate [platform, month]
   FileScan parquet
    PartitionFilters: platform = Shopee, year = 2022
    ReadSchema: struct<month:string>
```

Trích rút gọn từ outputs/spark_query_plan.txt, giữ các thành phần cần diễn giải.

Exchange hashpartitioning trong kế hoạch thể hiện việc trao đổi dữ liệu để GROUP BY, còn HashAggregate thể hiện tổng hợp. Nhóm sử dụng kế hoạch như bằng chứng giải thích cách query hoạt động, chưa coi đó là thí nghiệm định lượng tốc độ tăng bao nhiêu phần trăm. Đồ án chưa thực hiện benchmark lặp lại giữa một và hai worker trên các máy vật lý khác nhau.

4.5. THỰC HIỆN KHÍA CẠNH K MEANS VÀ LƯU KẾT QUẢ

Luật khía cạnh được thực hiện trước khi lưu processed, vì vậy batch, thống kê và streaming dùng cùng định nghĩa. Với dữ liệu mẫu phân cụm, CountVectorizer, IDF và Normalizer tạo feature pipeline; KMeans.fit chạy trên Spark. Mô hình, feature pipeline và gán cụm của mẫu được ghi vào HDFS cùng metadata để đọc lại.

Silhouette tính theo cosine trên mẫu đánh giá có giới hạn tối đa 10.000 dòng. Lần batch đầu cho khoảng 0,0221, lần qua Airflow khoảng 0,0191. Hai giá trị đều thấp, nên nhóm sử dụng kết quả như bằng chứng phân tách còn yếu, không chọn một giá trị để tuyên bố mô hình nhận diện tốt. Tham số seed giúp tái lập điều kiện nhưng không bảo đảm tuyệt đối mọi kết quả số học phân tán giống hệt từng bit.

Kết quả nhỏ được ghi bằng tệp tạm rồi thay thế nguyên tử. Cách ghi này được áp dụng để giảm nguy cơ công bố tệp ghi dở và cho phép các dịch vụ có UID khác nhau cùng cập nhật thư mục output theo quyền nhóm. Toàn bộ dữ liệu phân tích chi tiết vẫn được lưu trong HDFS, còn outputs chứa các bảng và bằng chứng phục vụ đọc nhanh.

4.6. THỰC NGHIỆM KAFKA VÀ CHECKPOINT

Nhóm replay 1.000 review từ mẫu kiểm tra phân tầng theo nền tảng và mức sao. Không dùng 1.000 dòng đầu của CSV để so sánh sàn, vì phần đầu nguồn tập trung chủ yếu vào Tiki. Producer gửi JSON với khóa ổn định; Kafka topic ecommerce-reviews có ba partition và một broker KRaft.

Consumer chạy hữu hạn bằng availableNow, maxOffsetsPerTrigger bằng 500. Bảng 4.4 trình bày số sự kiện duy nhất mới đã lưu theo từng microbatch. Đây là số sau stateful dedup, không đồng nhất với số offset Kafka đã đọc trong batch.

Bảng 4.4: Số review duy nhất mới trong hai lượt replay

Batch ID	Lượt replay	Review mới	Hợp lệ	Không hợp lệ
0	Lần 1	499	499	0
1	Lần 1	498	498	0
2	Lần 1	3	3	0
3	Lần 2	0	0	0
4	Lần 2	0	0	0
5	Lần 2	0	0	0

Sau hai lượt phát lại cùng tập, tổng end offset của topic là 2.000, gồm partition 0 là 662, partition 1 là 698 và partition 2 là 640. Parquet streaming vẫn có 1.000 dòng và 1.000 khóa duy nhất. Ba batch của lượt replay sau không tạo review mới. Kết quả này chứng minh tiến độ và state được phục hồi từ checkpoint trong tình huống thử nghiệm.

Nhóm không diễn giải kết quả này thành bảo đảm exactly-once tổng quát giữa mọi nguồn và sink. foreachBatch ghi theo batch_id có tính chất riêng; state dedup

không watermark cần được quản lý khi mở rộng. Những giới hạn đó là một phần của thiết kế, không bị che bởi việc số review sau replay đúng trong demo.

4.7. ĐIỀU PHỐI AIRFLOW VÀ ĐỐI SOÁT ĐẦU RA

Bảng 4.5: Trạng thái chín task trong lần kiểm chứng Airflow

Bước	Task ID	Trạng thái
1	01_prepare_hdfs	Success
2	02_upload_csv	Success
3	03_read_with_spark	Success
4	04_clean_to_parquet	Success
5	05_spark_sql	Success
6	06_review_aspects_and_kmeans	Success
7	07_save_results	Success
8	08_kafka_replay_and_stream	Success
9	09_verify_completion	Success

Lần chạy validation_20261012 đạt 9/9 task success. Trong quá trình kiểm tra, sự khác biệt quyền ghi giữa dịch vụ Spark và Airflow làm một bước ghi output thất bại; nhóm sử dụng tệp tạm và thay thế nguyên tử, sau đó chạy tiếp từ task lỗi. Việc phục hồi ở task phù hợp cho thấy vai trò của log, dependency và retry, thay vì xóa dữ liệu để làm lại toàn bộ quy trình.

Sau khi bổ sung lớp phục vụ, nhóm kiểm tra riêng task 07 tạo cube/chỉ mục và task 09 đối soát HDFS cùng chỉ mục. Cả hai thực thi thành công. Bằng chứng của lần DAG cơ bản và kiểm tra các task mở rộng được lưu riêng để không gộp thời gian từ các điều kiện chạy khác nhau thành một benchmark.

Job validate_persisted đọc lại dữ liệu thật từ HDFS và so sánh số dòng, số khóa duy nhất, tổng theo nền tảng và số streaming. Script validate_dashboard thực hiện GROUP BY độc lập trên toàn bộ chỉ mục để đối chiếu mọi ô cube Spark. Có 1.910 ô với chín số đếm mỗi ô khớp hoàn toàn, trong cùng generation. Nhóm sửa phép audit sang quét bảng tuần tự để tránh truy cập ngẫu nhiên tốn thời gian qua bind mount Windows.

4.8. KIỂM TRA TỰ ĐỘNG VÀ KHẢ NĂNG TÁI LẬP

Bảng 4.6: Nhóm kiểm tra tự động và kết quả

Nhóm kiểm tra	Số test	Nội dung chính	Kết quả
Chuẩn hóa văn bản	3	Unicode, dấu và phủ định, ký tự vô hình	Đạt
Logic Spark	2	CSV quoting/newline; quarantine và dedup	Đạt
Ghi artifact	2	Giữ bản trước khi ghi lỗi; thay thế Unicode	Đạt
Dashboard/chỉ mục	6	Mẫu số, tìm không dấu, generation, cache, rebuild	Đạt
Tổng	13	Chạy trong spark-client container	Đạt

Có 13 bài kiểm tra đạt trong container. Các bài kiểm tra tập trung vào những lỗi có thể thay đổi kết quả: CSV có dấu phẩy/dấu nháy/xuống dòng, Unicode và phủ định, quarantine, thứ tự dedup, giữ các ID khác nhau có cùng nội dung, bộ lọc và mẫu số, tìm không dấu, đồng bộ generation và giữ chỉ mục cũ khi rebuild thất bại. Kết quả test xác nhận những điều kiện đã kiểm tra, không bao phủ mọi lỗi vận hành có thể có.

Khả năng chạy lại được kiểm tra ở hai lớp. Batch từ cùng nguồn giữ nguyên các số đếm raw, clean, quarantine và duplicate ID. Streaming replay cùng ID giữ nguyên số review duy nhất nhờ checkpoint/state. Volume lưu HDFS, Kafka và Airflow được giữ qua các lần dừng dịch vụ; không xóa checkpoint khi muốn quan sát khả năng phục hồi.

Bảng 4.7: Thời gian nội bộ từng stage trong lần batch đầu

Stage	Thời gian nội bộ giây
inspect	27,648
clean	109,136
analyze	20,436
cluster	75,029
export	3,396

Thời gian ở Bảng 4.7 được đo trong từng stage của một lần chạy, không bao gồm đầy đủ mọi thao tác khởi động dịch vụ và không phải trung bình nhiều thí nghiệm. Nó giúp nhận biết bước làm sạch hoặc phân cụm tốn thời gian hơn trong cấu hình này. Nhóm chưa kết luận tốc độ mở rộng tuyến tính khi tăng worker hoặc dữ liệu.

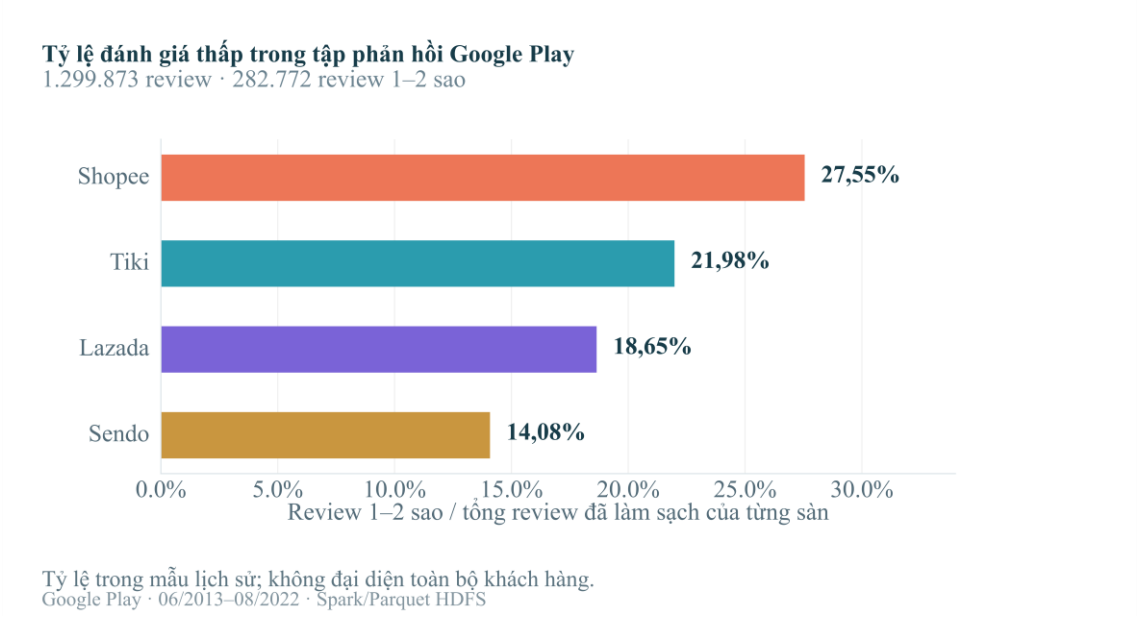
CHƯƠNG 5 KẾT QUẢ VÀ SẢN PHẨM

5.1. KẾT QUẢ THỐNG KÊ SAU LÀM SẠCH

Processed có 1.299.873 review, trong đó 282.772 review 1-2 sao, tương ứng 21,75%; điểm trung bình toàn tập khoảng 3,98/5. Đây là các chỉ số sau quarantine và dedup, khác với hồ sơ raw ở Chương 2. Tổng theo nền tảng khớp với số dòng được đọc lại từ Parquet HDFS.

Bảng 5.1: Thống kê review sau làm sạch theo nền tảng

Nền tảng	Review	Review 1-2 sao	Tỷ lệ 1-2 sao	Sao trung bình
Shopee	519.191	143.040	27,55%	3,7725
Lazada	530.404	98.905	18,65%	4,1119
Sendo	179.632	25.299	14,08%	4,2060
Tiki	70.646	15.528	21,98%	3,9957
Toàn tập	1.299.873	282.772	21,75%	3,9830



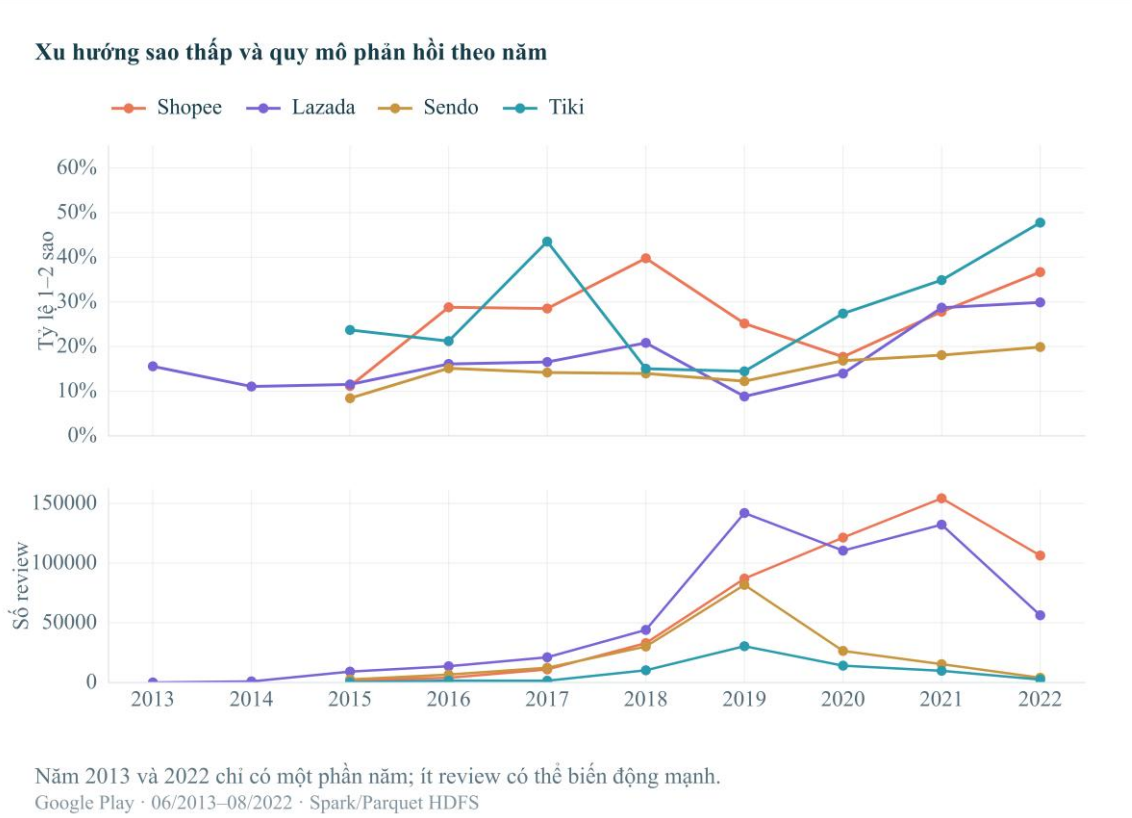
Hình 5.1: Tỷ lệ sao thấp của bốn nền tảng trong snapshot

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Shopee có tỷ lệ sao thấp cao nhất trong tập này, 27,55%, nhưng Lazada có số review nhiều hơn. Tiki có ít review hơn đáng kể so với hai sàn trên. Do dữ liệu

không đại diện mọi khách hàng, nhóm diễn giải Hình 5.1 như mô tả tập quan sát và dùng số đếm đi kèm để tránh xếp hạng dịch vụ chỉ từ một tỷ lệ tổng.

5.2. BIẾN ĐỘNG THEO THỜI GIAN



Hình 5.2: Tỷ lệ sao thấp và lượng review theo năm

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Hình 5.2 đặt tỷ lệ sao thấp cùng lượng review để người đọc thấy mẫu số thay đổi theo năm. Các năm có ít review có thể biến động mạnh; năm 2013 và 2022 chỉ chứa một phần năm. Tỷ lệ theo năm được tính từ tổng số sao thấp chia tổng review của năm đó, không lấy trung bình của các tỷ lệ tháng.

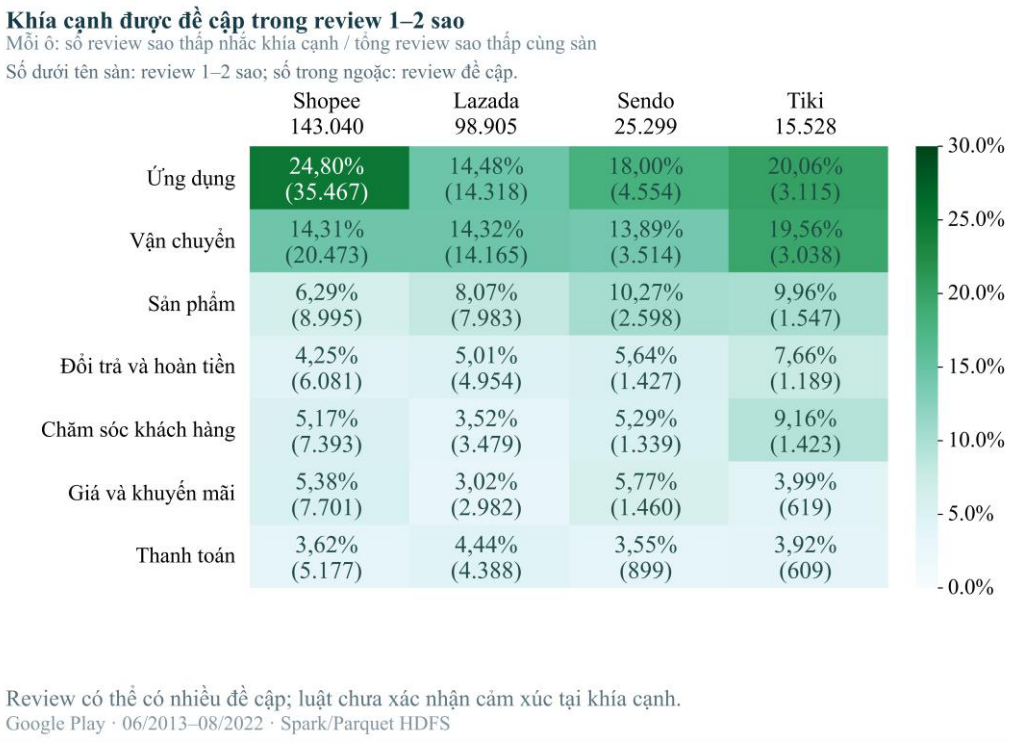
Thay đổi tỷ lệ có thể liên quan nhiều yếu tố như người viết, giai đoạn sử dụng và cách thu thập; đồ án không có dữ liệu kiểm soát để xác định một thay đổi giao diện hoặc chính sách gây ra đường biểu đồ. Nhóm dùng thời gian để khoanh vùng những nội dung cần xem lại, không để chứng minh nguyên nhân.

Một bộ lọc đã kiểm tra trên sản phẩm là Shopee từ 01/2021 đến 08/2022: 260.800 review, 81.979 review sao thấp và tỷ lệ 31,43%. Việc kết quả này khác tỷ lệ toàn lịch sử của Shopee là đúng do mẫu số và giai đoạn khác nhau. Giao diện hiển thị phạm vi đang chọn để người đọc không nhầm hai kết quả.

5.3. KHÍA CẠNH ĐƯỢC ĐỀ CẬP VÀ ĐỘ BAO PHỦ

Bảng 5.2: Số review sao thấp đề cập từng khía cạnh trên toàn tập

Khía cạnh	Review sao thấp đề cập	Tỷ lệ trên 282.772 review sao thấp
Ứng dụng	57.454	20,32%
Vận chuyển	41.190	14,57%
Sản phẩm	21.123	7,47%
Đổi trả và hoàn tiền	13.651	4,83%
Chăm sóc khách hàng	13.634	4,82%
Giá và khuyến mãi	12.762	4,51%
Thanh toán	11.073	3,92%



Hình 5.3: Ma trận tỷ lệ đề cập khía cạnh theo nền tảng

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Ứng dụng có 57.454 review sao thấp đề cập, vận chuyển có 41.190 và sản phẩm có 21.123. Đây là ba đầu mối có số lượng lớn trong bộ luật hiện tại. Ví dụ,

đề cập ứng dụng trong nhóm sao thấp của Shopee đạt 24,80%, còn Lazada là 14,48%. Đề cập vận chuyển trong nhóm của Tiki đạt 19,56%, so với khoảng 14% ở các sàn còn lại.

Ma trận Hình 5.3 dùng số review sao thấp của cùng sàn làm mẫu số. Mỗi review có thể xuất hiện ở nhiều ô thuộc các khía cạnh khác nhau. Nhóm không cộng các ô để suy ra số người dùng và không coi một khía cạnh được đề cập là chắc chắn bị đánh giá tiêu cực.

Bảng 5.3: Tỷ lệ có đề cập khía cạnh và phần chưa gán

Nền tảng	Có đề cập	Chưa gán	Tỷ lệ có đề cập	Tỷ lệ chưa gán
Shopee	67.857	75.183	47,44%	52,56%
Lazada	37.432	61.473	37,85%	62,15%
Sendo	11.326	13.973	44,77%	55,23%
Tiki	7.941	7.587	51,14%	48,86%

Toàn tập có 124.556 review sao thấp được gán ít nhất một đề cập, đạt độ bao phủ khoảng 44,05%; 158.216 chưa gán. Phần chưa gán có thể là phản hồi chung hoặc bị luật bỏ sót. Riêng Lazada có tỷ lệ chưa gán khoảng 62,15%. Kết quả này cho thấy cần kiểm tra mẫu độc lập trước khi đánh giá chất lượng bộ khía cạnh, không được xem các review chưa gán đều không chứa vấn đề cụ thể.

5.4. KẾT QUẢ KHÁM PHÁ K MEANS

K-Means được huấn luyện trên 61.241 vector khác 0 trong mẫu hash 25% đã lọc, với K bằng 8 và khoảng cách cosine. Các nhóm có từ khóa về ứng dụng, giao hàng, phí ship, quảng cáo, đặt hàng, đăng nhập hoặc chất lượng. Bảng 5.4 tóm tắt từ khóa nổi bật, không đặt tên nhóm như nhãn chuẩn.

Bảng 5.4: Từ khóa nổi bật của tám cụm khám phá

Cụm	Từ khóa nổi bật trong tâm cụm
1	dụng, ứng, ứng dụng, lag, càng, tệ, chậm, không
2	hàng, giao, giao hàng, không, đơn, mua, nhận, khách
3	như, hang, cc, vận, vận chuyển, chuyển, phí vận, con

Cụm	Từ khóa nổi bật trong tâm cụm
4	ship, lừa, đảo, lừa đảo, phí, cao, phí ship, ship cao
5	cáo, quảng, quảng cáo, cáo nhiều, nhiều, phiền, cáo hoài, hoài
6	đặt, đặt hàng, hàng, ko, không, đc, giao, không đặt
7	lỗi, đăng, nhập, ko, sao, đc, tải, bị
8	lượng, chất, phẩm, sản, sản phẩm, chất lượng, bán, kém

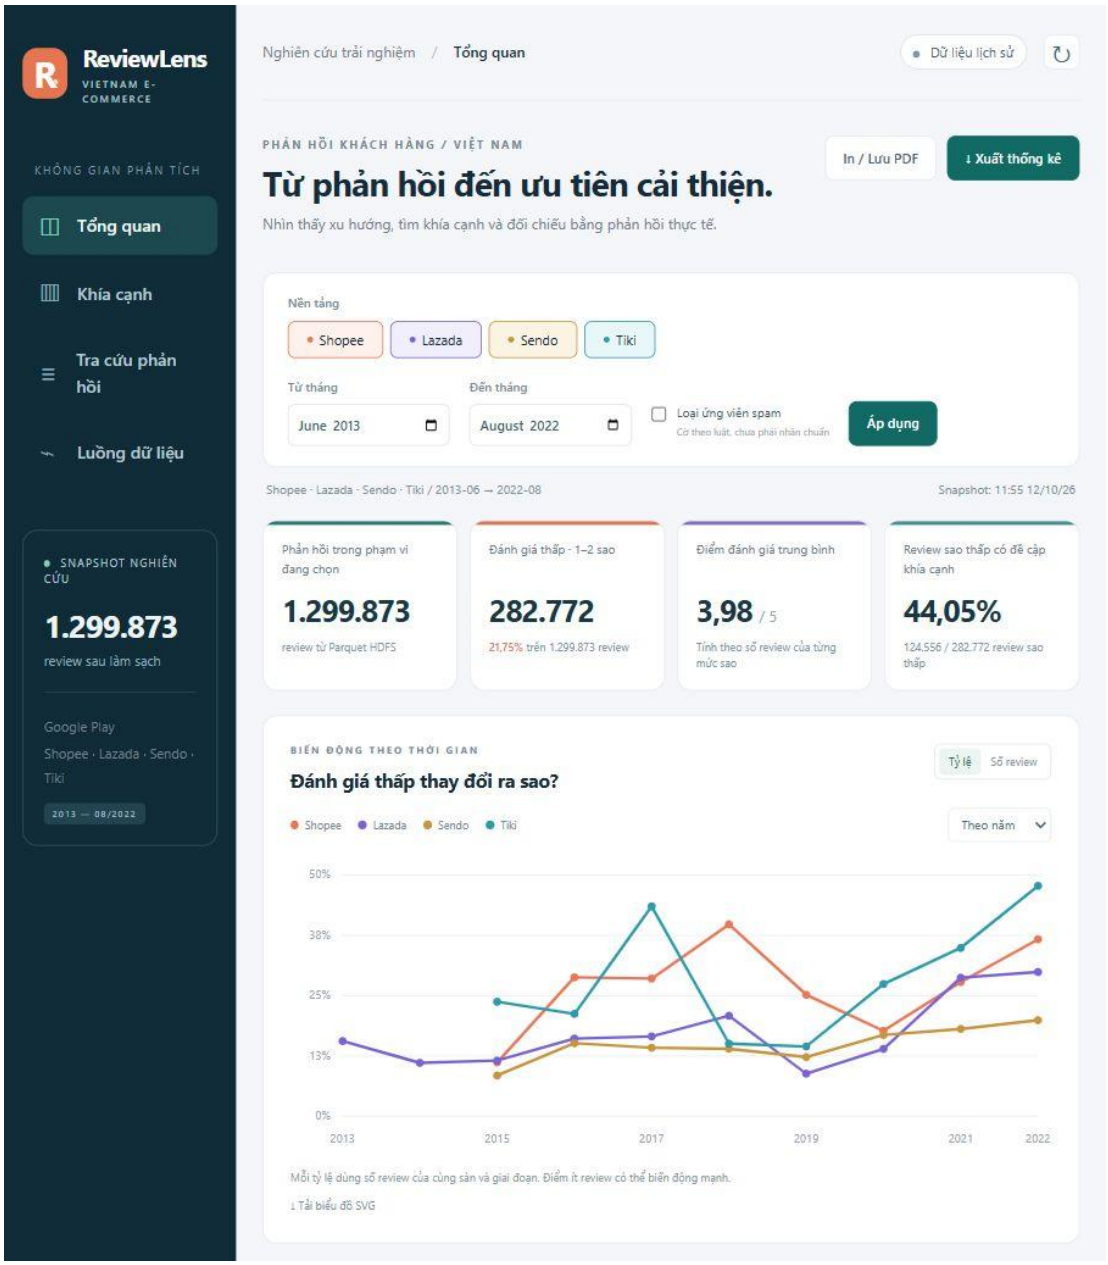
Silhouette của lần chạy qua Airflow khoảng 0,019 cho thấy phân tách yếu. Review ngắn, cách viết không thống nhất, nhiều nội dung lặp và cách tách âm tiết có thể hạn chế chất lượng biểu diễn. Nhóm xem những quan sát này như hướng kiểm tra tiếp, chưa có thí nghiệm tách riêng tác động của từng yếu tố.

Trong mẫu đã lưu có những ví dụ ngắn như “Đăng nhập là một cực hình” và “Ko đặt hàng được j hết là sao vậy”. Chúng minh họa tình huống có thể được kiểm tra từ cụm, nhưng không đủ đại diện toàn bộ thành viên cụm. Nhóm chưa có nhãn người đọc, nên không báo cáo accuracy, precision, recall hoặc F1 cho khía cạnh và không chuyển silhouette thành độ chính xác.

5.5. SẢN PHẨM QUAN SÁT REVIEWLENS

5.5.1. Các chức năng và nguồn số liệu

ReviewLens chạy tại http://localhost:8090 và có bốn màn hình: Tổng quan, Khía cạnh, Tra cứu phản hồi, Luồng dữ liệu. Tổng quan cung cấp chỉ số và biểu đồ; Khía cạnh cung cấp ma trận, độ bao phủ và cụm khám phá; Tra cứu cho phép tìm từ khóa, sàn, sao, khía cạnh và phân trang; Luồng dữ liệu trình bày các số đếm kiểm chứng cùng bằng chứng Airflow, Kafka và Spark SQL.



Hình 5.4: Màn hình Tổng quan của sản phẩm ReviewLens

Nguồn: dữ liệu và kết quả triển khai của nhóm.

Các số liệu biểu đồ đọc từ cube Spark, còn chỉ mục có đủ 1.299.873 review đã làm sạch. Bộ lọc sàn, tháng và ứng viên spam làm thay đổi cùng phạm vi tổng hợp; bộ lọc riêng tại tra cứu áp dụng cho danh sách văn bản. Phần K-Means dùng toàn snapshot của mẫu đã huấn luyện và được ghi rõ là không tính lại theo bộ lọc trang. Màn hình pipeline hiển thị bằng chứng lần kiểm tra đã lưu, không được xem là giám sát trực tiếp mọi dịch vụ.

Tìm kiếm chấp nhận không dấu và yêu cầu tất cả từ đã nhập xuất hiện trong review, không yêu cầu nằm cạnh nhau thành một cụm. Văn bản được thoát ký tự

khi hiển thị. Sản phẩm cho xuất thống kê CSV, tối đa 5.000 review theo bộ lọc, biểu đồ SVG và in trang hiện tại. Bộ hình PNG/SVG tĩnh phục vụ báo cáo được tạo từ bảng tổng hợp Spark theo toàn phạm vi snapshot.

5.5.2. Tình huống sử dụng để rà soát trải nghiệm

Người phân tích có thể chọn một nền tảng và giai đoạn, xem tỷ lệ sao thấp, mở ma trận khía cạnh rồi bấm ô ứng dụng hoặc vận chuyển để đọc review. Khi giữ toàn lịch sử, chọn Shopee, 1-2 sao, khía cạnh ứng dụng và tìm "dang nhap", hệ thống trả 4.764 review phù hợp. Con số là kết quả của điều kiện tìm kiếm, không phải số lỗi đăng nhập đã được xác minh.

Sau khi đọc ngữ cảnh, người phân tích có thể lập danh sách tình huống như xác minh tài khoản, lỗi truy cập hoặc chậm giao hàng để đối chiếu với hệ thống vận hành. Nếu muốn so sánh sàn, cần giữ cùng phạm vi thời gian và xem mẫu số. Việc kết nối log ứng dụng hoặc đơn hàng để xác minh từng lỗi chưa nằm trong bản triển khai này.

5.5.3. Kiểm tra thao tác và thời gian truy vấn

Nhóm kiểm tra bộ lọc, liên kết ma trận với review, tìm không dấu, phân trang và xuất tệp. CSV thống kê khớp số liệu bốn sàn; CSV tra cứu có đúng 4.764 review Shopee, sao không vượt 2 và có đề cập ứng dụng. SVG xuất ra có cấu trúc XML hợp lệ.

Một lần thử API khi cache sẵn sàng ghi nhận 0,033 giây cho tổng quan và 0,382 giây cho truy vấn trên, chưa phản ánh tải nhiều người. Lần đầu sau cập nhật có thể phải sao chép chỉ mục khoảng 400 MB; thời gian này được phân biệt với truy vấn sau khi cache sẵn sàng.

5.6. ĐÁNH GIÁ THEO MỤC TIÊU BIGDATA

Đường đi từ raw đến sản phẩm có bằng chứng: block HDFS, số record Spark, partition và shuffle, kế hoạch SQL, offset/state streaming và phụ thuộc Airflow. Đối soát số liệu giúp người xem giải thích nguồn gốc kết quả trên giao diện.

Hệ thống đáp ứng mục tiêu thực hành trên laptop. Nhận diện nội dung còn ở mức baseline; một DataNode và một broker chưa đáp ứng khả năng chịu lỗi sản xuất. Chưa có benchmark nhiều máy hoặc nguồn thu thập thật; chất lượng suy luận cần được đánh giá riêng.

KẾT LUẬN

1. KẾT QUẢ ĐẠT ĐƯỢC

Đồ án xây dựng được pipeline Bigdata cho bộ phản hồi ứng dụng thương mại điện tử tiếng Việt theo chín bước thực hành đã điều chỉnh phù hợp dữ liệu. Nguồn gồm 1.300.086 record, sau cách ly 74 record và loại 139 bản sao ID còn 1.299.873 review trong Parquet HDFS. Số dòng, khóa duy nhất và tổng theo nền tảng khớp khi đọc lại dữ liệu thật. Các lần chạy lại batch giữ nguyên số đếm của cùng nguồn.

Nhóm đã triển khai Spark SQL, bộ luật đề cập khía cạnh, thí nghiệm TF-IDF/K-Means, Kafka replay/Structured Streaming với checkpoint và DAG Airflow. Hai lần replay tạo 2.000 offset nhưng chỉ giữ 1.000 review duy nhất. Lần DAG cơ bản có 9/9 task success; các task mở rộng cho lớp phục vụ được kiểm tra riêng. Có 13 bài kiểm tra tự động đạt và mọi ô cube Spark khớp với phép tổng hợp độc lập trên chỉ mục.

Sản phẩm ReviewLens giúp quan sát xu hướng, so sánh phạm vi, xem khía cạnh và mở phản hồi gốc. Hình ảnh và bảng thống kê tạo đầu ra báo cáo; nguồn dữ liệu và mẫu số được giữ rõ. Những thành phần này kết nối kết quả kỹ thuật với một quy trình rà soát trải nghiệm có thể thực hiện tại máy.

2. HẠN CHẾ

Bộ dữ liệu là snapshot Google Play dừng ở 08/2022, không phải phản hồi giao dịch hiện tại và không đại diện toàn bộ khách hàng Việt Nam. Tỷ lệ sao thấp là tín hiệu thay thế; khía cạnh được nhắc chưa xác nhận khía cạnh đó bị chê hoặc gây ra đánh giá thấp. Bộ luật mới bao phủ khoảng 44,05% review sao thấp và chưa được đánh giá bằng nhãn người đọc.

K-Means có silhouette thấp và chỉ chạy trên mẫu hash đủ điều kiện. Cách tách âm tiết chưa xử lý đầy đủ đặc điểm tiếng Việt. Về hạ tầng, các container cùng một máy chia sẻ CPU/đĩa; HDFS replication bằng 1 và Kafka một broker không chứng minh khả năng chịu lỗi nhiều máy. State dedup không watermark tăng theo số ID, phù hợp demo hữu hạn nhưng cần thiết kế khác khi dữ liệu liên tục tăng.

3. HƯỚNG PHÁT TRIỂN

Ưu tiên về nội dung là đọc và gán nhãn mẫu độc lập theo khía cạnh và cảm xúc ở khía cạnh, phân biệt phản hồi chung với lỗi bỏ sót rồi đánh giá bằng chỉ số

phù hợp. Bộ mẫu 1.000 review đã chuẩn bị nhưng các nhãn vẫn để trống. Việc cải thiện luật hoặc thử phương pháp khác phải dựa trên lỗi quan sát được và giữ tập đánh giá độc lập.

Ưu tiên về hệ thống là thí nghiệm kích thước partition/file, đo lặp lại dưới tải cố định, thử cấu hình nhiều máy với replication phù hợp và thiết kế lưu trữ/upsert cho streaming dài hạn. Khi bổ sung nguồn mới cần kiểm tra schema, phạm vi và phiên dữ liệu trước khi công bố snapshot trên sản phẩm. Việc thu thập và tích hợp dữ liệu vận hành thực tế cần được thiết kế riêng.

Qua triển khai, nhóm xác định nền tảng của đồ án là dữ liệu có hợp đồng, xử lý có thể truy vết và kết quả có đối soát. Việc áp dụng mô hình nội dung hoặc bổ sung giao diện chỉ có giá trị khi giữ được những điều kiện đó. Đây là định hướng nhóm lựa chọn để tiếp tục hoàn thiện sản phẩm theo kiến thức môn học Bigdata.

TÀI LIỆU THAM KHẢO

Các tài liệu trực tuyến dưới đây được truy cập ngày 12/10/2026.

[1] Kaggle, hienbm. Vietnamese E-commerce Review. https://www.kaggle.com/datasets/hienbm/vietnamese-ecommerce-review.

[2] Apache Software Foundation. Hadoop 3.3.6 HDFS Architecture. https://hadoop.apache.org/docs/r3.3.6/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html.

[3] Apache Software Foundation. Spark 3.5.7 Cluster Mode Overview. https://spark.apache.org/docs/3.5.7/cluster-overview.html.

[4] Apache Software Foundation. Spark 3.5.7 RDD Programming Guide. https://spark.apache.org/docs/3.5.7/rdd-programming-guide.html.

[5] Apache Software Foundation. Spark 3.5.7 Parquet Files. https://spark.apache.org/docs/3.5.7/sql-data-sources-parquet.html.

[6] Apache Software Foundation. Kafka 3.9 Quick Start. https://kafka.apache.org/39/getting-started/quickstart/.

[7] Apache Software Foundation. Spark 3.5.7 Structured Streaming Programming Guide. https://spark.apache.org/docs/3.5.7/structured-streaming-programming-guide.html.

[8] Apache Software Foundation. Airflow 2.10.5 DAGs. https://airflow.apache.org/docs/apache-airflow/2.10.5/core-concepts/dags.html.

[9] Apache Software Foundation. Spark 3.5.7 Clustering. https://spark.apache.org/docs/3.5.7/ml-clustering.html.

[10] Apache Software Foundation. Spark 3.5.7 Extracting transforming and selecting features. https://spark.apache.org/docs/3.5.7/ml-features.html#tf-idf.

[11] SQLite. SQLite FTS5 Extension. https://www.sqlite.org/fts5.html.

[12] Apache Software Foundation. Spark 3.5.7 CSV Files. https://spark.apache.org/docs/3.5.7/sql-data-sources-csv.html.

PHỤ LỤC A ĐỐI CHIẾU YÊU CẦU VÀ MINH CHỨNG

Nhóm chọn hướng phân tích dữ liệu có số đếm, biểu đồ và diễn giải. TF-IDF/K-Means là thí nghiệm khám phá bổ sung trong Spark; tiêu chí cốt lõi vẫn là lưu trữ HDFS, xử lý phân tán, streaming có trạng thái và điều phối có kiểm tra.

Bảng PL.1 Ma trận đối chiếu yêu cầu nộp bài

Yêu cầu	Source và minh chứng
Nguồn, schema và quy mô	Chương 2; scripts/audit_dataset.py; evidence/verified_20261028/raw_inspection.json; 1.300.086 record, 642.967.981 byte.
HDFS và kiểm tra dữ liệu	scripts/bootstrap_hdfs.py; infra/hadoop; hdfs_blocks.txt và hdfs_report.txt.
Spark đọc trực tiếp HDFS	src/review_analytics/spark_ops.py: read_raw; jobs/batch_pipeline.py: inspect/clean; raw_inspection.json.
Làm sạch và SQL	clean, analyze; data_quality.json, platform_summary.csv, spark_query_plan.txt.
Phân tích và sản phẩm	Sáu bảng SQL; biểu đồ theo sàn/thời gian; ReviewLens dùng cube và chỉ mục xuất từ HDFS.
Kafka nếu dùng streaming	jobs/replay_kafka.py và stream_reviews.py; topic ba partition; log producer, microbatch và persisted_validation.json.
Airflow điều phối	dags/ecommerce_pipeline.py; validation_20261012 có 9/9 task success; log task 07/09 mở rộng riêng.
Khả năng tái hiện	README.md, docs/RUNBOOK.md, .env.example, scripts/Init-LocalConfig.ps1 và cấu hình Docker Compose.
Nhật ký và phân công	Phụ lục D và E; docs/WORK_LOG.md. Git mới ghi nhận từ lúc đóng gói ngày 28/10; không có commit hồi tố.

Repository mã nguồn công khai: https://github.com/sangpm2005/DA_BIGDATA. Các đường dẫn evidence/verified_20261028 trong phụ lục là bản sao đã chọn để kiểm tra trên repository, không phải khẳng định toàn pipeline được chạy lại ngày 28/10.

PHỤ LỤC B ĐỐI SOÁT BỔ SUNG NGÀY 15 THÁNG 10

Các số trong Chương 4 về hai lượt replay là thử nghiệm lịch sử ngày 12/10. Những lần phát lại tiếp theo làm tăng số batch; không thay đổi số unique nếu giữ cùng ID và checkpoint. Bảng dưới ghi đúng kết quả bổ sung đang lưu tại thời điểm tổng hợp.

Bảng PL.2 Các kết quả bổ sung có thể đối chiếu

Chỉ số	**Giá trị**
Processed HDFS	1.299.873 dòng và 1.299.873 khóa duy nhất
Tổng platform_summary	1.299.873 review
Streaming HDFS	1.000 dòng và 1.000 khóa duy nhất
Số microbatch đã lưu	12
Batch không có ID mới	9
Generation sản phẩm	3803e26d88584384995a5fdbcf9fa37a
Đối soát cube và index	1.910 nhóm x 9 số đếm đều khớp; index có 1.299.873 review
Thời điểm đối soát cube	15/10/2026 15:59:21 giờ Việt Nam
Silhouette bổ sung	0,020008

Nguồn kiểm tra: persisted_validation.json, dashboard_validation.json, dashboard_preparation.json và cluster_metadata.json. Giá trị silhouette bổ sung khoảng 0,0200 khác lần 12/10 khoảng 0,0191; cả hai đều cho thấy phân tách yếu. Không lấy khác biệt này làm bằng chứng cải thiện độ chính xác.

End offset là vị trí kế tiếp trong từng partition. Tổng 2.000 ở thử nghiệm ban đầu không phải số review unique; cũng không phải công thức đếm message tổng quát sau retention. foreachBatch mặc định có ngữ nghĩa ghi at-least-once; ghi theo batch_id hỗ trợ retry nhưng không tạo giao dịch nguyên tử cho mọi output.

Ảnh giao diện ở Chương 5 được giữ theo snapshot đã chụp ngày 12/10. Snapshot chuẩn bị lại ngày 15/10 có cùng tổng review; không gán ảnh cũ thành ảnh của lần chạy mới.

PHỤ LỤC C LỆNH CHẠY VÀ ĐIỀU KIỆN TÁI HIỆN

Môi trường cần Docker Desktop ở chế độ Linux containers, PowerShell và đủ RAM cho các dịch vụ. Tải CSV từ Kaggle, đặt tên vietnamese_ecommerce_review.csv tại thư mục gốc. Các artifact lớn được tạo lại, không tải từ Git. Không dùng dữ liệu có schema khác mà giữ nguyên các số kỳ vọng.

Chuẩn bị cấu hình và hạ tầng

```
git clone https://github.com/sangpm2005/DA_BIGDATA.git
cd DA_BIGDATA
.\scripts\Init-LocalConfig.ps1
py -3.11 scripts/audit_dataset.py
docker compose build spark-client
docker compose up -d namenode datanode spark-master spark-worker-1 `
    spark-worker-2 spark-client
docker compose exec -T spark-client python scripts/bootstrap_hdfs.py
```

Init-LocalConfig.ps1 tạo .env cục bộ với giá trị ngẫu nhiên cho database và tài khoản Airflow; không ghi đè .env đã có. Mật khẩu, API key và token không nằm trong repository. Nếu dùng volume cũ phải giữ thông tin đăng nhập của volume đó.

Chạy batch và lớp phục vụ

```
docker compose exec -T spark-client spark-submit --master `
    spark://spark-master:7077 --driver-memory 2g --executor-memory 1g `
    jobs/batch_pipeline.py --stage all
docker compose exec -T spark-client spark-submit --master `
    spark://spark-master:7077 jobs/prepare_dashboard.py
docker compose exec -T spark-client python `
    scripts/build_dashboard_index.py
docker compose exec -T spark-client python scripts/validate_dashboard.py
docker compose --profile dashboard up -d dashboard
```

Chạy tuần tự, chỉ tiếp tục sau khi lệnh trước thành công. README và RUNBOOK nêu lệnh Kafka producer/consumer, connector Spark 3.5.7, Airflow init/Trigger và kiểm tra HDFS. Các URL là localhost:9870, :8081, :4040 khi Spark application hoạt động, :8080 và :8090.

PHỤ LỤC D NHẬT KÝ KỸ THUẬT VÀ XỬ LÝ LỖI

Nhật ký này tổng hợp từ log, artifact và thay đổi mã nguồn đang có. Các mốc là ngày có minh chứng; không biến kế hoạch năm tuần thành lịch sử chấm công.

Bảng PL.3 Công việc và lỗi có dấu vết kiểm tra

Mốc	Nội dung và bằng chứng
12/10	Audit CSV và batch HDFS/Spark; count khớp; hdfs_blocks.txt, batch_full.log, data_quality.json.
12/10	Lỗi quyền ghi giữa Spark/Airflow: dùng tệp tạm và os.replace; tests_after_io_fix.log; tiếp tục DAG từ task lỗi.
12/10	Kafka replay hai lượt; stream_first.log, demo_evidence.json và metric batch 0-5; output không tăng ID trùng.
12/10	Task 07 mở rộng tạo cube/index. Task 09 audit toàn index đổi sang quét tuần tự để tránh đọc ngẫu nhiên qua bind mount Windows.
15/10	Kiểm tra Engine trên Windows PowerShell 5.1 nhận ExitCode null: sửa probe dùng Process handle và đọc stdout/stderr; xác nhận phiên bản Docker.
15/10	Đối soát bổ sung HDFS/streaming và cube/index; dashboard_validation.json gắn generation của snapshot ngày 15/10.
28/10	Đối chiếu yêu cầu nộp PDF; chuẩn bị repository, bỏ cấu hình mật khẩu khỏi Git, bổ sung hướng dẫn và hai bản báo cáo.

Repository được khởi tạo ngày 28/10/2026. Commit từ thời điểm này ghi nhận việc đóng gói và rà soát mã nguồn; không đại diện lịch sử triển khai trước đó. Nhóm không tạo commit lùi ngày hoặc gán tác giả cho Thể/Vĩ khi chưa có bằng chứng Git tương ứng.

PHỤ LỤC E PHÂN CÔNG CÂN BẰNG TRONG NĂM TUẦN

Nhóm phân công mỗi thành viên một gói chính mỗi tuần và một lượt kiểm tra chéo. Tổng khối lượng kế hoạch mỗi người là năm gói chính và năm lượt rà soát, tỷ trọng dự kiến 1/3. Trách nhiệm dưới đây không phải số giờ hoặc xác nhận đóng góp đã hoàn tất.

Tuần 1 Khảo sát bài toán và chuẩn bị môi trường

Bảng PL.4 Phân công tuần 1

Thành viên	Công việc và đầu ra
Huỳnh Quang Sang	Xác định câu hỏi phân tích, phạm vi và chỉ số sao thấp. Đề cương, định nghĩa mẫu số và giới hạn dữ liệu.
Phan Đức Thể	Khảo sát schema CSV, số record, dữ liệu rỗng và trùng. Script audit, hồ sơ dữ liệu và SHA-256.
Đỗ Trọng Vĩ	Chuẩn bị Docker Compose, HDFS và Spark hai worker. Cấu hình dịch vụ, ảnh worker và kiểm tra HDFS.

Tuần 2 Lưu trữ và làm sạch dữ liệu bằng Spark

Bảng PL.5 Phân công tuần 2

Thành viên	Công việc và đầu ra
Huỳnh Quang Sang	Tạo vùng HDFS, upload raw và kiểm tra block. Script bootstrap, log fsck và fingerprint nguồn.
Phan Đức Thể	Đọc CSV nhiều dòng, chuẩn hóa và tách quarantine. Job PySpark, reason lỗi và số đếm raw/quarantine.
Đỗ Trọng Vĩ	Khử trùng ID, ghi Parquet và đối soát số dòng. Window dedup, partition platform/year và kiểm tra khóa.

PHỤ LỤC E PHÂN CÔNG TUẦN BA ĐẾN TUẦN NĂM

Tuần 3 Phân tích và tạo kết quả có thể kiểm chứng

Bảng PL.6 Phân công tuần 3

Thành viên	Công việc và đầu ra
Huỳnh Quang Sang	Thực hiện Spark SQL theo sàn, thời gian và số sao.
Phan Đức Thể	Xây luật đề cập bảy khía cạnh và kiểm tra phần chưa gán.
Đỗ Trọng Vĩ	Triển khai TF-IDF và K-Means trên mẫu hash.

Tuần 4 Streaming và điều phối quy trình

Bảng PL.7 Phân công tuần 4

Thành viên	Công việc và đầu ra
Huỳnh Quang Sang	Tạo Kafka topic và producer phát lại review có ID ổn định.
Phan Đức Thể	Triển khai Structured Streaming, checkpoint và thử replay.
Đỗ Trọng Vĩ	Tạo DAG Airflow, kiểm tra phụ thuộc, retry và quyền ghi.

Tuần 5 Tích hợp sản phẩm và chuẩn bị nộp bài

Bảng PL.8 Phân công tuần 5

Thành viên	Công việc và đầu ra
Huỳnh Quang Sang	Tạo cube, chỉ mục tìm kiếm và đối soát lớp phục vụ.
Phan Đức Thể	Hoàn thiện biểu đồ, bộ lọc, tra cứu và kiểm thử sản phẩm.
Đỗ Trọng Vĩ	Tổng hợp báo cáo, minh chứng, mã nguồn và kịch bản demo.

Rà soát chéo: Sang kiểm tra gói của Thể; Thể kiểm tra gói của Vĩ; Vĩ kiểm tra gói của Sang. Việc cân bằng được xem xét theo độ phức tạp và đầu ra, không chỉ theo số dòng code. Chưa có dữ liệu commit hoặc bảng giờ để kiểm chứng đóng góp cá nhân trong giai đoạn trước khi tạo Git.

PHỤ LỤC F ĐỐI CHIẾU MÃ NGUỒN VÀ KẾT QUẢ CHẠY

Source cốt lõi của bước đọc dữ liệu

```
def read_raw(spark, path: str) -> DataFrame:
    return (spark.read.schema(RAW_SCHEMA).option("header", True)
        .option("multiLine", True).option("quote", '"').option("escape", '"')
        .option("mode", "PERMISSIVE").option("enforceSchema", True)
        .option("columnNameOfCorruptRecord", "_corrupt_record").csv(path))
```

Trích src/review_analytics/spark_ops.py, hàm read_raw. Nguồn HDFS được truyền từ stage inspect/clean. Sau parse, pipeline repartition, kiểm tra, dùng Window khử trùng rồi ghi Parquet; file nhiều dòng có một reader partition trước bước phân phối.

Kết quả đối soát lưu trên HDFS

```
{
  "verification": "passed",
  "processed_rows": 1299873,
  "processed_unique_keys": 1299873,
  "streaming_rows": 1000,
  "streaming_unique_keys": 1000,
  "streaming_batches": 12
}
```

DAG và kiểm tra cuối

```
prepare >> upload >> read >> clean >> sql >> clustering >> export >> kafka >>
complete

09_verify_completion:
  verify_outputs.py --require-stream
  validate_persisted.py
  validate_dashboard.py --outputs /exports
```

Trong source, ba lệnh kiểm tra cuối nối bằng &&. Exception hoặc assert không đạt làm lệnh thất bại và task không thể hoàn tất bình thường. Trong môi trường chạy chuẩn không bật tối ưu Python -O để tránh bỏ qua assert.

Các bản source đầy đủ cùng README được cung cấp tại https://github.com/sangpm2005/DA_BIGDATA. Thư mục evidence/verified_20261028 gồm metadata, bảng tổng hợp nhỏ, log chọn lọc, ảnh và manifest SHA-256 để đối chiếu. Không đưa raw review, tên/ảnh người viết, tập annotation chứa văn bản, index SQLite hoặc volume lên repository.